山东大学本科毕业论文（设计）

面向 AI 生成内容的安全性研究与工具开发

姓名：麦世徐

学号：202200460157

专业：网络空间安全

指导教师：郭山青

2026 年 4 月 26 日

摘　要

随着生成式人工智能技术的快速发展，AI 生成内容在图像生成、视频生成、数字人驱动与智能创作等领域得到广泛应用，但同时也带来了虚假合成内容传播、不安全内容扩散、身份伪造和平台审核压力增加等问题。围绕 AIGC 内容在真实应用场景中的安全风险，本文以图像与视频两类典型媒体为研究对象，研究虚假内容检测与不安全内容识别方法，并在此基础上设计实现一个多模态内容安全检测与分析平台。

本文首先梳理 AIGC 生成技术、深度伪造技术以及安全检测领域的发展现状，分析现有方法在检测对象、泛化能力、部署成本和工程适配性等方面的特点。随后，围绕图像与视频安全分析任务，构建由前端展示层、后端代理层和模型推理层组成的系统架构，整合本地部署检测模型与外部多模态审核接口，形成统一的内容输入、检测分析、风险分级与结果可视化流程。系统支持图像与视频文件上传、URL 输入、虚假内容鉴别、不安全内容审核、检测结果展示与内容管理等功能，可为实验评估、样本构建和应用验证提供平台支撑。

在实验与分析部分，本文结合当前系统实现情况，对图像虚假检测、视频内容分析、不安全内容审核和平台可用性进行验证。结果表明，本地图像检测模块能够在 ProGAN mini 子集上完成稳定的基线验证，后端代理层能够将本地模型与外部多模态接口统一封装为可展示结果，平台已形成从内容生成、内容检测到风险展示的基本闭环。本文工作兼顾工程实现与应用价值，可为 AIGC 内容安全治理、网络平台审核以及多模态安全研究提供参考。

关键词：AIGC 安全；多模态检测；虚假内容检测；不安全内容识别；内容安全平台

ABSTRACT

With the rapid development of generative artificial intelligence, AI-generated content has been widely used in image synthesis, video generation, digital human animation, and intelligent media creation. Its increasing realism and accessibility also bring security risks such as forged content dissemination, unsafe media generation, identity misuse, and moderation pressure. Focusing on practical AIGC security scenarios, this thesis studies fake content detection and unsafe content recognition for images and videos, and designs a multimodal content security detection and analysis platform.

This thesis reviews AIGC generation technologies, deepfake manipulation methods, and mainstream detection approaches, comparing their detection targets, generalization ability, deployment cost, and engineering adaptability. Based on this analysis, a three-layer architecture is proposed, including the front-end presentation layer, back-end proxy layer, and model inference layer. By combining locally deployed detectors with external multimodal review APIs, the platform builds a unified workflow for content input, security analysis, risk grading, and result visualization. It supports image and video upload, URL-based input, fake content identification, unsafe content review, and output management.

In the experimental analysis, image fake detection, video content analysis, unsafe content review, and platform usability are verified according to the current implementation. The local image detector is evaluated on a ProGAN mini subset as a reproducible baseline, and the back-end proxy converts local model outputs and external API responses into structured results for front-end visualization. The results show that the platform has formed a basic closed loop from content generation and detection to risk presentation, providing a practical reference for deployable AIGC content governance tools.

Key words: AIGC security, fake content detection, multimodal review, content security platform

目录

第一章 绪论 **1**
1.1 研究背景与意义 1
1.2 国内外研究现状 1
1.2.1 AIGC 生成技术研究现状 1
1.2.2 AI 生成内容检测研究现状 2
1.2.3 不安全内容审核研究现状 2
1.2.4 现有研究的不足与问题分析 3
1.3 研究内容与技术路线 3
1.3.1 主要研究内容 3
1.3.2 技术路线 4
1.4 论文特色与创新点 4
1.5 论文结构安排 4

第二章 相关技术与理论基础 **6**
2.1 AIGC 图像与视频生成技术基础 6
2.1.1 图像生成技术演进 6
2.1.2 视频生成技术路线 7
2.1.3 AIGC 生成内容的安全相关特征 7
2.2 Deepfake 与多模态内容伪造技术 8
2.2.1 面向人脸的深度伪造技术 8
2.2.2 面向通用场景的多模态伪造与编辑技术 8
2.3 虚假内容检测方法 8
2.3.1 基于低层统计与频域特征的检测方法 8
2.3.2 基于监督分类的检测方法 9
2.3.3 基于通用视觉表征与重建对比学习的检测方法 9
2.3.4 面向视频的时序检测方法 10
2.3.5 不同检测方法的比较与适用场景 10
2.4 不安全内容检测与安全审查方法 10
2.4.1 内容安全审查的任务目标 10
2.4.2 基于视觉分类的内容审核方法 11

2.4.3 基于多模态大模型的安全审查方法 12
2.4.4 生成安全评测与防护研究的启示 12
2.5 系统开发关键技术 12
2.5.1 前端交互与可视化技术 12
2.5.2 后端代理与服务编排技术 13
2.5.3 模型服务化部署技术 13
2.6 本章小结 13

第三章 系统需求分析与总体设计 14
3.1 系统建设目标 14
3.2 功能需求分析 15
3.2.1 图像与视频输入 15
3.2.2 虚假内容检测 16
3.2.3 不安全内容审核 16
3.2.4 内容生成、展示与管理 17
3.3 非功能需求分析 17
3.3.1 可扩展性需求 17
3.3.2 可维护性需求 18
3.3.3 响应性能需求 18
3.3.4 安全性与可部署性 18
3.4 系统总体架构设计 19
3.4.1 总体架构设计思路 19
3.4.2 前端展示层设计 19
3.4.3 后端代理层设计 20
3.4.4 模型推理与外部能力层设计 20
3.5 系统核心业务流程设计 20
3.5.1 内容检测流程设计 20
3.5.2 生成与闭环验证流程设计 21
3.5.3 结果管理与追踪流程设计 21
3.6 模块划分与接口关系设计 22
3.6.1 功能模块划分 22
3.6.2 统一输入输出设计 22
3.6.3 模块间协同关系 23
3.7 本章小结 23

第四章 关键模块与平台实现 24
4.1 多源检测框架实现 24
4.1.1 统一能力组织思路 24
4.1.2 输入参数与结果结构标准化 25

4.2 图像虚假内容检测模块实现 25
4.2.1 本地检测模型接入实现 25
4.2.2 外部图像 AI 鉴别接口接入实现 26
4.3 视频虚假内容检测模块实现 28
4.3.1 视频理解接口接入实现 28
4.3.2 视频检测结果结构化实现 28
4.4 不安全内容检测模块实现 28
4.4.1 图像安全审核模块实现 28
4.4.2 视频安全审核模块实现 29
4.5 样本生成与内容管理模块实现 29
4.5.1 生成模块实现 29
4.5.2 数据管理模块现状与实现方式 30
4.6 风险分级与可视化展示实现 31
4.7 前后端平台开发与部署实现 31
4.7.1 前端页面与交互实现 31
4.7.2 后端代理与任务调度实现 32
4.7.3 模型服务部署实现 33
4.8 本章小结 33

第五章 实验设计与结果分析 34
5.1 实验目标与取舍原则 34
5.2 实验环境与评价指标 35
5.2.1 实验环境 35
5.2.2 评价指标 35
5.3 数据集与测试样本构建 36
5.3.1 图像真假检测样本 36
5.3.2 视频与安全审核样本 36
5.3.3 实验样本组织策略 37
5.4 图像虚假内容检测实验与分析 37
5.4.1 实验目的与方案 37
5.4.2 阶段性结果分析 37
5.5 视频检测与安全审核验证 38
5.5.1 视频真假检测验证 38
5.5.2 不安全内容审核验证 40
5.5.3 功能验证结果讨论 40
5.6 系统性能与可用性分析 41
5.6.1 响应特征分析 41
5.6.2 平台可用性分析 41

5.7 实验结果综合分析 42
5.8 本章小结 43

第六章 总结与展望 **44**
6.1 全文工作总结 44
6.2 存在的不足 45
6.3 后续研究展望 46

参考文献 **47**

致谢 **50**

附录 **51**
附录 A 补充代码与接口说明 51
附录 B 运行与复现实验说明 51

第一章　绪论

1.1　研究背景与意义

近年来，生成式人工智能技术快速演进，基于生成对抗网络、扩散模型以及多模态大模型的内容生成方法在图像生成、视频生成、数字人驱动、图像编辑和智能创作等任务中表现出较强能力 [1, 4, 6]。AIGC 技术显著提高了数字内容生产效率，降低了内容制作门槛，在媒体传播、广告营销、教育培训、智能交互和数字娱乐等领域展现出广阔应用前景。然而，伴随生成质量不断提升，AI 生成内容与真实内容之间的边界逐渐模糊，其安全风险也日益凸显。

在图像与视频场景中，AIGC 带来的风险主要体现在三个方面。其一，虚假内容风险，即利用文生图、图生视频、换脸、属性编辑等技术生成高度逼真的伪造内容，进而用于误导用户、制造舆论或实施诈骗。其二，不安全内容风险，即借助生成模型输出暴力、色情、仇恨、违法违规等不当信息，对网络空间治理和平台审核造成压力。其三，平台治理风险，即面对海量多模态内容时，单纯依赖人工审核已经难以兼顾效率、准确性与一致性，亟需自动化、可扩展的技术工具辅助安全分析与风险处置。

在这一背景下，围绕 AIGC 内容的真实性与安全性展开研究具有明显的理论意义和应用价值。从理论层面看，系统梳理 AIGC 图像与视频的安全风险类型，比较不同检测方法的适用条件与技术特征，有助于完善多模态内容安全分析的研究框架。从应用层面看，构建面向真实业务场景的安全检测与分析平台，有助于为内容审核、新闻核验、网络治理、品牌保护以及个人权益维护提供技术支撑。因此，开展面向 AIGC 安全的多模态内容检测与分析研究，不仅契合网络空间安全领域的实际需求，也具有较强的工程实践价值。

1.2　国内外研究现状

1.2.1　AIGC 生成技术研究现状

图像生成技术是 AIGC 发展的重要基础。早期研究主要依赖生成对抗网络，通过对抗训练实现图像分布建模，在人脸生成、图像翻译和风格迁移等任务中取得了较好效果 [1, 2, 3]。近年来，扩散模型凭借更稳定的训练过程和更优秀的生成质量，逐渐成为主流技术路线 [4, 5]。以 Stable Diffusion 为代表的文生图模型在高分辨率图像生

成、语义对齐与细节表达等方面表现突出，并促进了文本到图像、图像编辑和多条件控制等应用的发展 [6, 7, 19]。随着相关模型的开源与社区工具链完善，图像生成技术的可获取性显著提高，也使得伪造内容的构造门槛不断降低。

视频生成技术则在时序建模、多帧一致性与跨模态对齐方面持续发展。文本到视频、图像到视频和数字人驱动等技术路线不断成熟，使模型能够根据文本提示或参考图像生成具备连续动作和场景变化的短视频内容。与此同时，Deepfake、人脸替换、人脸动画和属性编辑等深度伪造技术在视觉真实感、动作自然度和局部细节一致性方面持续提升。这些技术一方面为影视制作、虚拟人交互等提供了新工具，另一方面也提升了虚假视频的欺骗性和传播风险，使多模态内容安全问题更加复杂。

1.2.2　AI 生成内容检测研究现状

针对 AI 生成图像与视频的检测问题，国内外研究已形成多条技术路线。较早的方法通常从纹理分布、频域伪影、颜色统计或成像噪声等低层特征出发，利用真实内容与伪造内容之间的分布差异进行判别 [9, 22]。这类方法对特定模型或特定数据集往往具有较好效果，但在面对新型生成模型时容易出现泛化不足的问题。

随着深度学习的发展，基于卷积神经网络的伪造检测方法逐渐成为研究重点。这类方法通过监督学习自动提取图像或视频中的判别特征，能够较好地适应复杂视觉模式 [13, 14]。但随着生成模型迭代加快，仅依赖某一类训练数据训练得到的检测器在跨模型迁移时仍可能面临性能下降。为提升泛化能力，研究者进一步开始利用大规模预训练视觉模型的通用表征能力，构建跨生成模型的检测方法 [8, 10, 12]。此类方法通常以预训练特征为基础，结合轻量分类头或重建对比机制，在未知生成模型场景中表现出更好的鲁棒性。

在视频检测方向，除传统逐帧分类和时序特征建模外，训练自由检测方法、局部与全局联合分析方法以及面向深度伪造特征的专用模型也不断出现。这些方法通常更加关注视频中的时序连续性、嘴型与语音一致性、局部区域不协调等问题。与此同时，多模态大模型逐渐被用于图像和视频的真假判别，能够结合视觉内容与自然语言提示完成结构化分析，在工程上具有较高灵活性。不过，大模型判别仍存在结果稳定性、成本控制和可解释性不足等问题。

1.2.3　不安全内容审核研究现状

相较于真实性检测，不安全内容审核更强调对暴力、色情、仇恨、政治敏感与其他违规信息的识别能力。传统内容审核方法主要建立在图像分类、目标检测与多标签识别模型之上，针对固定类别场景可取得较好性能。随着多模态大模型的发展，安全审核系统开始结合视觉输入与自然语言规则，实现更灵活的内容理解与风险判断，在复杂场景中展现出更强的泛化潜力。

然而，从实际部署角度看，单一方法往往难以同时满足识别范围、推理效率、工程成本与可维护性要求。本地审核模型通常具备自主可控和便于定制的优点，但部署

与更新成本较高；外部审核接口则接入便捷、覆盖面较广，却存在外部依赖和调用成本问题。因此，如何将多源检测能力进行统一组织，并通过平台化方式形成可用的安全分析工具，成为当前研究与工程实践中的关键问题。

1.2.4　现有研究的不足与问题分析

综合现有研究可以发现，AIGC 安全分析仍面临以下几方面问题。首先，图像与视频检测往往分散在不同任务框架中，缺乏能够同时支持多模态输入和多类风险识别的一体化平台。其次，已有方法在实际落地时常常面临“算法效果”与“工程可用性”之间的矛盾，本地模型、云端接口和多模态大模型各有优缺点，但缺少统一的组织与比较机制。再次，检测结果的可解释表达、风险分级展示和应用验证流程仍不够完善，难以直接服务于教学、科研和平台治理场景。基于这些问题，本文拟从系统集成与工程实现的角度出发，构建一个兼顾研究价值与落地可行性的多模态内容安全分析平台。

1.3　研究内容与技术路线

1.3.1　主要研究内容

围绕 AIGC 图像与视频内容的真实性风险与安全性风险，本文主要开展以下几方面工作。

第一，构建面向平台实现的 AIGC 内容安全问题框架。本文将 AIGC 风险拆分为虚假内容风险、不安全内容风险与平台治理风险三个层面，并进一步区分图像、视频两类输入媒介的检测需求。该部分工作不追求对所有生成模型逐一展开，而是为后续系统需求、模块划分和实验取舍建立统一问题边界。

第二，研究多源检测能力的组织方式。针对图像虚假检测，本文接入本地 UniversalFakeDetect 模型作为可控、可复验的检测基线；针对图像与视频开放场景检测，本文接入多模态理解接口完成真假鉴别与安全审核；针对不同接口返回结构不一致的问题，本文设计了统一的输入参数、结果字段和风险分级表达，使多类检测能力能够在同一平台中协同工作。

第三，设计并实现面向 AIGC 安全的多模态内容检测与分析平台。平台采用前端展示层、后端代理层、模型推理与外部能力层相分离的结构，实现内容上传、URL 输入、图像/视频虚假检测、图像/视频安全审核、内容生成、结果可视化和检测记录组织等功能。该系统既能支持实验验证，也能用于功能展示和模型扩展。

第四，围绕平台可用性与检测链路有效性开展实验验证。本文结合仓库中的 ProGAN 测试样本、平台生成样本和典型图像/视频素材，设计图像真假检测、视频检测、安全审核和系统可用性验证方案。实验部分重点说明当前平台“哪些能力已经可稳定运行、哪些能力适合作为研究基线、哪些能力仍依赖外部接口并需要后续补强”，避

免脱离系统完成度堆砌不可靠指标。

1.3.2　技术路线

本文的技术路线总体上遵循“问题分析、方法整合、平台实现、实验验证”的思路展开。首先，通过调研 AIGC 生成与检测领域的相关技术，明确论文所关注的两类核心任务，即虚假内容检测与不安全内容识别，并梳理图像与视频两类媒体的检测需求。其次，结合现有开源模型与外部审核接口，构建统一的检测能力接入框架，并通过后端代理实现鉴权封装、接口转发、异步轮询和结果标准化处理。再次，在前端构建面向用户的交互页面，实现内容上传、检测触发、结果展示与数据管理等功能，形成较为完整的分析闭环。最后，围绕检测效果、系统响应性能和平台可用性等方面设计实验与测试方案，为论文结论提供支撑。

1.4　论文特色与创新点

结合当前课题目标与平台建设情况，本文的工作特色与创新点主要体现在以下几个方面。

第一，面向图像与视频场景，构建了兼顾虚假内容检测与不安全内容识别的多模态安全分析框架。与仅关注单一检测任务的系统相比，本文更强调从实际应用场景出发，将“是否为 AI 生成”和“内容是否存在违规风险”拆分为相互独立但可联合展示的两类判断，使平台能够覆盖更完整的内容安全工作流。

第二，提出并实现了本地模型与外部接口相结合的混合检测架构。该架构在工程上兼顾自主可控性与快速接入能力：本地 UniversalFakeDetect 模型用于形成可复验的图像检测基线，外部多模态接口用于补充视频理解、开放场景鉴别和安全审核能力，后端代理层则负责消解不同能力之间的协议差异。

第三，将检测结果可视化、风险分级与平台交互设计纳入整体研究范围，强化了论文在工程实现和应用落地方面的完整性。平台不只返回模型原始响应，而是将真假结论、置信度、风险标签、处置建议和说明文本统一组织为可展示结果，为样本构建、实验比较和系统演示提供支撑。

需要说明的是，本文的创新主要集中在多源检测能力整合、系统设计与工程实现以及实验评估框架设计方面，重点不在于提出全新的底层检测算法，而在于将已有模型、生成能力和审核能力组织为一个可运行、可验证、可扩展的安全分析平台。这一定位与本文的系统设计与实现型毕业论文主题相一致。

1.5　论文结构安排

本文共分为六章，内容安排如下。

第一章为绪论，主要介绍研究背景与意义、国内外研究现状、本文的研究内容与技术路线、特色与创新点以及论文整体结构安排。

第二章为相关技术与理论基础，介绍 AIGC 图像与视频生成技术、深度伪造技术、虚假内容检测方法、不安全内容审核方法以及系统实现所需的关键技术。

第三章为系统需求分析与总体设计，围绕平台目标、功能需求、非功能需求和总体架构展开分析，并给出核心模块划分与业务流程设计。

第四章为关键模块与平台实现，重点介绍多源检测框架设计、图像与视频检测模块实现、不安全内容审核模块实现、风险分级与可视化展示以及前后端平台开发过程。

第五章为实验设计与结果分析，介绍实验环境、数据集与测试样本、评价指标、检测实验、系统性能测试以及实验结果讨论。

第六章为总结与展望，对全文工作进行总结，分析现阶段仍存在的不足，并对后续模型扩展、系统优化和应用落地方向进行展望。

第二章　相关技术与理论基础

AIGC 安全分析涉及生成模型、伪造检测、内容审核和平台工程实现等多类技术。为了支撑系统建设，需要先明确图像与视频生成内容的技术来源、虚假内容检测的主要路线、不安全内容审核的任务特点，以及前后端分离、代理调度和模型服务化在平台中的作用。本章围绕上述内容展开，为多模态内容检测与分析平台的设计提供技术依据。

2.1　AIGC 图像与视频生成技术基础

2.1.1　图像生成技术演进

图像生成技术的发展大致经历了从生成对抗网络到扩散模型的演进过程。生成对抗网络通过生成器与判别器之间的对抗训练学习数据分布，在人脸生成、图像翻译、风格迁移和属性编辑等任务中取得了较早的突破 [1, 2, 3]。该类方法的优点在于生成速度较快，能够在较低推理成本下获得较好的视觉效果，但训练过程往往不够稳定，容易出现模式崩塌，且在复杂场景和高分辨率图像生成方面存在一定局限。

扩散模型的提出改变了图像生成领域的主流技术路线。其基本思想是将真实图像逐步加噪至近似高斯噪声，再训练模型学习逆向去噪过程，从而由噪声逐步恢复出符合文本条件或其他条件约束的图像 [4, 5]。以 Latent Diffusion Model 及其工程化代表 Stable Diffusion 为代表的模型，通过在潜空间而非像素空间中进行扩散与去噪，显著降低了计算成本，并在文本对齐、高分辨率细节表达和可控生成能力方面取得了良好效果 [6, 7, 19]。与传统 GAN 方法相比，扩散模型在复杂场景生成、语义一致性和编辑灵活性方面更具优势，因此已成为当前文生图、图像编辑和多条件控制任务的主流框架。

从安全分析视角看，图像生成技术的演进意味着伪造内容的来源更加多样。早期针对 GAN 指纹、频域伪影和颜色分布异常的检测思路，在面对扩散模型生成图像时不一定仍然有效。扩散模型生成内容在纹理细节、局部噪声模式和语义一致性上与真实图像更加接近，这直接提高了检测任务的难度，也对检测方法的泛化能力提出了更高要求。

2.1.2　视频生成技术路线

相比图像生成，视频生成不仅需要保证单帧视觉质量，还需要兼顾时间维度上的运动连续性和语义一致性。因此，视频生成模型通常要同时处理空间建模与时序建模两个问题。当前较为常见的路线包括文本到视频、图像到视频以及基于人脸或人体驱动的动画生成三类。

文本到视频模型通常以文本描述作为条件，通过时空联合建模从噪声中逐步生成视频序列。该类模型往往结合文本编码器、时空扩散网络以及视频解码器等多个子模块，以实现从语义描述到动态画面的映射。图像到视频模型则通常在给定首帧图像或参考图像的基础上生成连续帧，更强调主体身份保持、局部结构稳定和动作合理性。与此不同，面向数字人驱动和表情迁移的动画模型通常以关键点、运动场或驱动视频为中间表示，重点解决人物表情、口型、姿态等动态特征的迁移问题。

以本文原型系统中接入的 ModelScope Text-to-Video 类模型为例，其本质上属于基于扩散机制的文本到视频生成模型，通常采用三维卷积或时空注意力结构对视频潜变量进行建模 [20]。这类模型能够生成较为自然的短视频片段，但在复杂动作、长时一致性、文字渲染和高保真物理规律表达方面仍存在不足。也正因为如此，视频生成内容中常常会出现局部闪烁、运动不连续、结构漂移和时序逻辑不自然等问题，这些现象为视频安全检测提供了重要线索。

2.1.3　AIGC 生成内容的安全相关特征

从检测角度看，生成模型并非只意味着“更强的内容生产能力”，还意味着“可被识别的技术痕迹”。尽管不同模型产生的伪影形式并不相同，但 AIGC 生成内容通常在以下几个方面呈现可供分析的特征。

第一，低层统计特征差异。生成内容在噪声分布、纹理连续性、频谱结构和压缩残留模式等方面往往与自然采集图像存在差异。第二，局部语义不协调。对于复杂场景、细粒度结构或人脸部位，生成模型可能在局部细节上出现不合理现象，例如边缘结构不稳定、局部区域不连贯等。第三，时序动态异常。视频生成模型虽然能够产生连续帧，但在长时间尺度下仍可能表现出运动规律不自然、物体轨迹不稳定和帧间差异异常等问题。第四，安全对齐不足。生成模型在接收到具有诱导性、规避性或攻击性的提示词后，可能输出具有暴力、色情或其他违规属性的内容，这也是内容安全审查所关注的重要对象。

上述特征决定了本文研究需要同时关注两类任务：一类是识别内容是否由 AI 生成或被深度伪造，另一类是识别内容本身是否具有不安全属性。前者更强调真实性与来源分析，后者更强调内容风险等级与平台治理要求。两类任务既有交叉，也有明显差异，因此在技术上通常需要采用不同的检测思路。

2.2　Deepfake 与多模态内容伪造技术

2.2.1　面向人脸的深度伪造技术

Deepfake 是 AIGC 安全研究中最具代表性的风险场景之一。广义上看，深度伪造是指利用深度学习模型对人脸身份、表情、口型、语音或姿态等进行替换、重建和驱动的技术集合 [13, 14, 21, 22]。从任务形态上，可以将其大致分为身份替换、表情迁移、口型同步和属性编辑几类。

身份替换任务通常以源人脸和目标场景为输入，将源身份迁移到目标图像或视频中，核心难点在于保持身份特征、光照条件和局部融合自然度的一致。表情迁移任务更关注将驱动视频或驱动关键点中的面部运动映射到静态人物图像上，使目标人物能够完成张嘴、眨眼、点头等动作。口型同步则重点解决语音与嘴部运动的一致性问题，在虚拟人生成和伪造视频制作中均有应用。属性编辑任务则通过文本或标签控制对年龄、发型、妆容、背景和面部局部特征进行修改，虽然未必直接改变人物身份，但同样可能被用于误导性内容生成。

从本文课题角度看，人脸相关生成技术的重要性在于其风险后果更直接。相比一般风景或物体图像，人物图像和人物视频更容易触发身份冒用、名誉损害、舆论误导和诈骗场景，因此相关伪造内容既是虚假检测的重要对象，也是系统功能设计时必须重点覆盖的典型输入类型。

2.2.2　面向通用场景的多模态伪造与编辑技术

除人脸伪造外，当前 AIGC 技术还可用于生成通用场景图像、短视频片段、广告素材、新闻配图乃至高度拟真的事件片段。从安全角度看，这意味着伪造风险已经从“人脸换脸”扩展到“任意内容构造”。在图像层面，文生图模型可以根据自然语言快速构造新闻场景、灾害画面或拟真肖像；在视频层面，文本到视频和图像到视频模型可以进一步生成带有动作和镜头变化的动态内容，使内容看上去更具真实性。

与人脸深度伪造相比，通用场景伪造在检测上更难依赖固定的局部区域规则。人脸伪造任务常可聚焦于面部区域、表情肌理和身份一致性，而通用场景内容则可能涉及物理规律错误、对象关系异常、时序动作不自然以及语义逻辑不一致等更广泛的问题。这也意味着检测方法不能仅依赖某一类局部伪影，而需要具有更强的开放域泛化能力。

2.3　虚假内容检测方法

2.3.1　基于低层统计与频域特征的检测方法

较早的伪造检测研究主要依赖图像处理与媒体取证思想，通过分析图像在颜色分布、噪声模式、压缩残留、插值痕迹和频域特征上的异常来识别伪造内容 [9, 15, 22]。

这类方法的基本前提是：真实采集图像通常遵循相机成像链路和自然场景统计规律，而经过生成或编辑后的图像在这些规律上会产生偏离。

该路线的优点在于可解释性较强，通常能够指出异常出现的位置或类型，适合与传统数字取证方法结合使用。同时，这类方法在面对某些明显伪造、简单篡改和特定生成模型样本时具有较好效果。然而，其局限也较为明显。一方面，随着生成模型质量提高，很多早期明显的低层伪影已经被削弱；另一方面，这类方法对图像后处理、压缩、裁剪和分辨率变化较为敏感，跨模型和跨场景的泛化能力通常不足。因此，在当前 AIGC 环境下，低层统计方法更多起到辅助分析作用，而较少单独构成完整解决方案。

2.3.2　基于监督分类的检测方法

随着深度学习在视觉任务中的普及，伪造检测逐渐转向监督分类范式。该类方法通常将问题建模为二分类或多分类任务，利用卷积神经网络、Transformer 或其他视觉编码器，从真实样本与伪造样本中学习判别边界 [9, 11]。面向人脸伪造的检测任务中，FaceForensics++ 等公开数据集为该类方法提供了较为统一的训练与评估基础，大量研究围绕面部区域裁剪、局部注意力机制、压缩鲁棒性和多任务联合学习展开 [13]。

监督分类方法的优势在于能够自动学习复杂伪造特征，并在封闭数据分布内取得较高精度。对于训练集与测试集来源一致、伪造方法相近的场景，此类方法通常具有良好的检测性能。但其关键问题在于对数据分布的依赖较强。当测试样本来自训练阶段未见过的新型生成模型、不同压缩链路或不同模态时，性能往往明显下降。换言之，这类方法较适合作为特定场景下的专用检测器，而不一定天然适用于开放环境中的通用 AIGC 检测。

2.3.3　基于通用视觉表征与重建对比学习的检测方法

为解决监督分类方法在跨模型场景下的泛化不足问题，研究者开始探索基于通用视觉表征的检测路线。此类方法通常利用大规模预训练视觉模型或视觉语言模型提取图像特征，再通过近邻搜索、线性分类头或轻量探测器判断样本的真实性 [8]。UniversalFakeDetect 就是这一思路的典型代表。该方法并不依赖从零开始训练复杂的伪造分类器，而是借助大规模预训练特征空间中的判别能力，提高对未知生成模型的适应性 [10]。

与之相近的另一类工作是通过重建、对比学习和困难样本构造增强检测器的泛化能力。以 DRCT 为代表的方法强调：如果模型能够区分那些与真实图像高度相似的“困难伪造样本”，则其在面对未知扩散模型时也更有可能保持性能稳定 [12]。此类方法通常通过生成高质量重建样本、引入对比约束或改进训练目标，引导模型聚焦更稳定的生成痕迹，而非依赖某个特定模型的表面伪影。

从研究趋势看，基于通用表征和重建对比学习的方法更符合当前 AIGC 检测的发展方向。因为在生成模型快速迭代的现实背景下，检测器不可能针对每个新模型都重

新大规模训练。具有更强跨域泛化能力的方法，更适合支撑本文面向真实场景的通用化安全分析平台。

2.3.4　面向视频的时序检测方法

视频检测相较于图像检测多出一个时间维度，因此检测思路也更强调时序一致性、动作规律和帧间差异分析。传统视频伪造检测方法通常采用逐帧检测后再进行时序聚合，或者直接使用三维卷积网络、循环网络和时空 Transformer 对短视频片段进行建模。这些方法在深度伪造人脸视频场景中取得了一定效果，但对开放域 AIGC 视频的泛化能力仍有限。

近年来，面向通用 AI 生成视频的研究开始重视训练自由或弱训练检测方法。以 D3 为代表的方法从时间差分和二阶动态特征出发，强调真实视频与 AI 生成视频在运动变化规律上的差异，并通过无需大规模训练的方式完成检测 [16]。这类方法的启示在于：对于视频内容而言，单帧图像足够逼真并不意味着时间序列也自然合理。生成视频往往在物理连续性、局部运动稳定性和跨帧结构一致性上暴露更多问题，因此时序特征是视频检测中不可忽视的重要维度。

2.3.5　不同检测方法的比较与适用场景

综合来看，不同虚假内容检测方法之间并不存在绝对优劣，而是呈现出明显的适用场景差异。基于低层统计的方法可解释性较强，但对复杂开放场景适应性不足；基于监督分类的方法在特定数据分布内表现优秀，但跨模型泛化较弱；基于通用表征和重建对比的方法更适合开放环境中的图像检测，但往往对预训练特征质量和数据组织方式有较高要求；面向视频的时序检测方法能够利用动态异常提升判别能力，但在计算复杂度和数据处理链路上通常更复杂。

本文将主要检测路线的特征归纳如表 2.1 所示。综合检测效果、泛化能力和工程可用性等因素，平台采用“本地图像检测模型 + 外部多模态理解能力”的组合方案。

对于本文的研究目标而言，单一方法难以同时满足图像与视频、多源输入、工程可用性和扩展性的需求。因此，从全局设计角度看，采用“本地模型 + 外部多模态接口”的混合思路更加合理：本地模型适合作为可控、可复现的研究基线，外部接口则可弥补多模态和通用场景覆盖能力上的不足。这一判断也将直接影响系统架构与功能模块的设计。

2.4　不安全内容检测与安全审查方法

2.4.1　内容安全审查的任务目标

与虚假内容检测不同，内容安全审查关注的不是“内容是否由 AI 生成”，而是“内容本身是否违反平台规则、法律规范或伦理要求”。在 AIGC 场景下，这一任务的

表 2.1: 虚假内容检测方法比较

方法类别	主要依据	优势	局限与适用场景
低层统计与频域方法	噪声、纹理、频谱、压缩痕迹	可解释性较强，适合媒体取证辅助分析	对后处理敏感，面对高质量扩散模型时泛化不足
监督分类方法	标注数据中学习到的判别边界	封闭数据集内精度较高，部署链路成熟	依赖训练分布，跨生成模型和跨压缩链路容易退化
通用视觉表征方法	大规模预训练模型特征空间	泛化能力较好，适合作为开放域图像检测基线	对预训练特征质量敏感，通常仍需阈值或轻量分类头
视频时序检测方法	帧间一致性、运动规律、动态差分	能利用单帧图像中不明显的时序异常	计算和数据处理成本较高，本地部署复杂度更大
多模态大模型判别	视觉输入与自然语言提示联合推理	接入灵活，适合开放场景解释与快速原型	成本、稳定性和可解释依据仍需平台层面约束

重要性体现在两个层面：一方面，生成模型可能被用来主动制造暴力、色情、仇恨、毒品、赌博或其他违规内容；另一方面，即便内容不是明显违规，也可能在边界模糊场景中造成审核难题，例如擦边内容、暗示性表达、未成年人相关风险和符号化仇恨表达等。

因此，内容安全审查通常需要给出的不仅是一个简单的二分类结果，还包括风险类别、建议处置方式、风险等级以及必要的原因说明。对于本文系统而言，不安全内容检测的目标并不是替代最终人工审核，而是通过自动化分析提供第一道筛查和辅助判定能力。

2.4.2　基于视觉分类的内容审核方法

较为传统的内容审核方法通常建立在图像分类、目标检测与多标签识别模型基础之上。对于暴力、色情、血腥、毒品、武器和符号化风险内容，研究者可以通过构建特定类别的数据集，训练卷积神经网络或视觉 Transformer 完成分类或区域识别。该类方法的优点在于任务定义清晰、推理速度较快、部署链路成熟，适合在已知风险类别较为明确的业务场景下使用。

但其局限也较为明显。首先，不安全内容的边界本身具有较强语境依赖，仅凭视觉局部特征有时难以完成准确判断。其次，面对复合场景、隐喻表达或多模态语义风险时，单纯分类方法的表现会受到限制。再次，图像审核和视频审核虽然在风险类别上具有相似性，但视频任务还需要考虑时间维度上的动作过程和上下文语义，这使得模型设计更加复杂。

2.4.3　基于多模态大模型的安全审查方法

多模态大模型的出现为内容安全审查提供了新的技术路线。这类方法能够同时接收图像、视频与文本提示，并在统一语义空间内对内容进行理解和判断。相较于传统分类器，多模态大模型在开放类别识别、复杂语义推理和结构化结果生成方面具有优势，尤其适合用于需要“判断 + 解释 + 风险建议”一体输出的场景。

在工程实践中，多模态大模型通常可以通过精心设计提示词，将审核任务形式化为结构化输出问题。例如，可以要求模型围绕暴力、色情、仇恨、敏感符号、违法活动等类别给出安全结论、标签集合和处置建议。这种方式的好处在于扩展性强、接入灵活，尤其适合快速构建原型系统和覆盖复杂场景。然而，它也存在结果稳定性受提示词影响、成本较高、推理延迟不可忽视以及内部决策依据不完全透明等问题。因此，在真实系统中，多模态审核通常更适合作为规则系统和传统分类器的补充，而非完全替代。

2.4.4　生成安全评测与防护研究的启示

除了对输出内容进行事后审核，近年来研究者也开始关注生成模型本身的安全评测与前置防护。例如，面向视频生成场景的 T2VSafetyBench 从多类风险维度出发，对文本到视频模型的安全性进行系统评估，说明视频生成不仅需要关注画质与时序一致性，还应重视内容安全风险 [17]。类似地，面向多模态有害性识别的数据集与评测研究也表明，生成安全问题正在从“输出检测”逐步扩展到“全流程治理”[18]。

对本文而言，这类研究的主要意义不在于直接照搬其方法，而在于提供两个启示。第一，AIGC 安全分析不应仅局限于真假鉴别，还需要同时考虑内容合规性和风险处置逻辑。第二，安全研究可以分为生成前防护、生成中约束和生成后检测三个阶段，而本文平台主要聚焦于生成后检测与分析，因此需要在结果展示和风险标签设计上兼顾治理视角。

2.5　系统开发关键技术

2.5.1　前端交互与可视化技术

面向 AIGC 安全分析的平台不仅要完成检测任务本身，还需要为用户提供清晰、稳定和可理解的交互界面。因此，前端部分需要承担多模态输入管理、检测流程触发、结果可视化和历史信息展示等职责。React 与 TypeScript 的组合适合构建模块化、组件化的前端系统，其中 React 提供声明式界面开发能力，TypeScript 增强类型约束与可维护性，Vite 则能够提供轻量、快速的开发与构建体验。

前端展示层的核心价值在于把复杂的模型调用过程转化为清晰的用户操作流程。对于内容检测平台而言，前端需要稳定支持文件上传、链接输入、任务选择、进度反

馈、结果可视化和历史记录查看等交互能力，使用户能够以统一方式使用不同检测与审核功能。

2.5.2　后端代理与服务编排技术

由于本文涉及本地模型服务、外部审核接口以及多种输入输出协议，后端层需要承担统一代理与服务编排功能。采用 Node.js 与 Express 构建后端代理具有实现成本低、异步处理能力较强和与前端生态衔接自然等优点。后端代理层的核心作用不只是简单转发请求，更重要的是在系统中承担鉴权封装、参数校验、结果标准化、异步任务轮询和错误处理等职责。

从架构角度看，这一层是实现“多源检测能力统一组织”的关键。若缺少后端代理，前端将不得不直接面向多套接口协议与密钥体系，既不利于安全性，也不利于系统扩展。因此，后端代理技术是将研究原型转化为可部署平台的重要基础。

2.5.3　模型服务化部署技术

本文所涉及的本地检测与生成功能需要以服务化形式接入平台，因此模型服务化部署技术也是系统实现的重要基础。以 FastAPI 为代表的 Python Web 框架能够较方便地将深度学习模型封装为 HTTP 接口，适用于图像检测、视频处理和内容生成等推理任务。结合 PyTorch 及相关推理框架，可以实现模型加载、输入预处理、结果后处理和状态监测等功能。

模型服务化的价值在于，它将算法模型从单机实验脚本转化为可复用、可调度的系统组件，为统一代理和模块化接入创造条件。同时，服务化部署还要求在显存管理、并发控制、容错处理和远程部署方面进行工程优化。对于多模型集成平台而言，服务化不是附属工作，而是模型能力能够被稳定调用和持续扩展的前提条件。

2.6　本章小结

本章系统梳理了 AIGC 图像与视频生成技术、Deepfake 与多模态内容伪造技术、虚假内容检测方法、不安全内容审核方法以及平台实现所依赖的关键工程技术。综合分析可知，当前 AIGC 安全研究呈现出两个显著特点：一方面，生成模型不断演进，导致伪造内容来源更加多样、逼真程度更高；另一方面，检测与审核方法各有优势和局限，单一技术路线难以同时兼顾泛化能力、工程可用性和多模态覆盖范围。因此，面向真实应用场景的 AIGC 安全平台需要采用多源能力协同、结果结构统一和模块化部署相结合的设计思路。

第三章　系统需求分析与总体设计

多模态 AIGC 安全分析平台需要将图像、视频、生成模型、检测模型和外部审核接口组织为统一系统。仅有单个模型或单个页面并不能支撑完整的安全分析任务，平台还需要明确输入形式、任务边界、结果结构、模块职责和部署约束。本章围绕系统建设目标、功能需求、非功能需求、总体架构和业务流程展开分析，将课题目标转化为可实现的系统设计方案。

3.1　系统建设目标

本文所研究的系统并不是一个单纯的模型演示页面，而是一个围绕 AIGC 安全分析任务构建的多模态内容检测与分析平台。该平台的建设目标可以概括为“面向图像与视频内容，形成可接入、可分析、可展示、可扩展的 AIGC 安全研究原型”。围绕这一目标，系统设计需要同时满足研究验证、工程演示和后续扩展三个层面的要求。

从研究验证角度看，平台应能够承载虚假内容检测与不安全内容审核两类核心任务，并支持本地模型与外部接口的统一接入。这样做的原因在于，本文的目标并非局限于调用某一个现成接口，而是希望在统一平台中比较不同检测能力的适用场景、组织方式和可扩展性。因此，系统必须具备多源模型管理与统一结果表示能力。

从工程演示角度看，平台需要具备完整的交互闭环，包括内容输入、任务触发、结果返回、风险展示和历史追踪等环节。只有在业务链路上形成闭环，系统才能既服务于实验验证，又能够支撑功能展示和持续扩展。换言之，平台不仅要“能跑通模型”，还要“能被用户使用”，这也是本文区别于纯算法复现工作的一个重要特征。

从持续扩展角度看，系统应具备灵活的模块替换能力。AIGC 安全研究处于快速发展阶段，无论是生成模型还是检测方法都在持续迭代。如果平台在设计之初就将不同模型、不同输入模态和不同结果结构紧密耦合，模型替换和能力扩展成本会非常高。因此，系统需要在架构层面保持较强的松耦合特征，使前端界面、后端代理、模型服务和外部接口之间能够通过统一协议协同工作。

基于上述分析，本文将系统设计目标进一步细化为以下几点：第一，支持图像与视频两类输入媒介，并兼容文件上传和链接输入两种常见方式；第二，支持虚假内容检测和不安全内容审核两类安全任务；第三，支持本地模型与外部接口协同工作，形成多源能力统一接入框架；第四，支持检测结果可视化、风险分级和历史管理；第五，支持内容生成与检测联动，为样本构建与实验验证提供平台基础。围绕这些目标展开

的需求分析，将直接决定系统总体架构与模块划分方式。

图 3.1: 平台首页与整体功能模块

3.2　功能需求分析

3.2.1　图像与视频输入

作为面向多模态内容的安全分析平台，系统首先需要解决输入层面的统一性问题。本文关注的对象包括静态图像和短视频两类内容，它们在文件格式、体积大小、预处理流程和展示方式上存在明显差异。因此，系统必须在输入环节兼顾统一性与差异性：统一性体现在用户操作方式和业务入口要尽量一致；差异性体现在图像与视频需要采用不同的预处理与展示逻辑。

具体而言，系统应至少支持本地文件上传与 URL 输入两种方式。本地上传适用于实验样本、个人素材和平台生成结果的直接检测，能够保证研究过程中样本来源可控；URL 输入则更贴近实际应用场景，能够用于快速分析网络内容或远程素材。由于图像与视频的体积差异较大，系统在接收本地文件时还需要考虑大小限制、预览生成和编码转换问题。对于图像，可以较方便地进行 Base64 编码和前端预览；而对于视频，则需要在文件大小、上传方式和播放预览之间做权衡，以防止系统在前端或后端阶段出现性能瓶颈。

此外，输入需求不仅包括“能上传内容”，还包括“能识别内容类型并进入正确流程”。平台应能够区分图像检测、视频检测、图像安全审核和视频安全审核等不同

业务分支，并在前端交互层面为用户提供明确的任务选择入口。否则，即使底层能力充足，也会因为用户操作路径混乱而降低平台可用性。

3.2.2　虚假内容检测

虚假内容检测是本文系统的核心能力之一，其目标是判断输入内容是否由 AI 生成、是否经过深度伪造或是否存在明显合成痕迹。结合第一章和第二章的分析，可以看出该任务既包括开放域图像检测，也包括视频真假判别，还涉及人脸换脸、图像编辑和文生视频等多类伪造来源。因此，系统在功能设计上必须兼顾任务的通用性与检测结果的可理解性。

首先，系统应支持图像虚假检测与视频虚假检测两类子任务，并允许不同检测后端并行存在。对于图像检测，平台既需要支持本地模型完成较可控的研究复现，也应支持调用外部多模态模型完成更开放场景下的真假判别。对于视频检测，由于本地视频检测模型复现成本较高、资源消耗较大，系统还需要允许外部接口作为现实可行的主方案。这样的设计使平台能够在“研究可控性”和“工程适用性”之间取得平衡。

其次，虚假内容检测需求并不止于输出一个真假标签。更有价值的是提供结构化结果，包括真假结论、置信度、模型来源、必要的原因说明以及可选的辅助判断信息。这样做有两方面意义：一方面，它能够提升结果可解释性，使用户能够理解模型判断依据；另一方面，它也为多模型比较、风险融合和实验统计提供统一数据基础。

再次，系统需要支持“生成—检测”联动。考虑到本文课题不仅研究检测，还涉及内容生成与样本构建，因此虚假检测模块应能够方便接收平台内部生成的图像与视频结果，并完成即时分析。换言之，检测系统既要能分析外部输入，也要能分析平台自身生成的输出，这一点对于实验样本构建和闭环验证至关重要。

3.2.3　不安全内容审核

与虚假内容检测相比，不安全内容审核更强调内容风险类型与处置建议的输出。系统需要识别的并不是“内容是真是假”，而是“内容是否涉及暴力、色情、仇恨、赌博、敏感符号或其他违规属性”。这意味着审核模块在设计上必须同时支持标签化分类、风险等级判断和说明性输出。

从任务形式上看，不安全内容审核同样需要同时支持图像和视频。对于图像审核，重点是识别静态场景中的违规内容类别；对于视频审核，除了识别单帧场景中的不安全元素，还需要考虑整段视频语义和时序动作过程所带来的风险。这种模态差异决定了系统不能简单地将图像审核逻辑直接复制到视频流程中，而是需要在交互入口、输入参数和结果呈现方式上做有针对性的区分。

在结果设计方面，审核模块应至少输出安全与否、风险标签、建议处置方式和原因说明。其中，建议处置方式可以设计为“通过”“复审”“阻断”等层次，用于体现平台对不同风险程度内容的区分能力。这样设计不仅更接近真实业务平台的审核逻辑，也便于在系统中实现统一的风险分级展示。

此外，不安全内容审核需求与虚假内容检测需求之间应保持相互独立但可联合展示的关系。某些内容可能是 AI 生成但不一定违规，某些内容可能真实拍摄却包含高风险信息。因此，系统设计不能将两类任务简单合并为一个判断器，而应允许它们分别输出各自结果，并在界面层面统一呈现。这种设计有助于形成清晰的风险分级与结果解释机制。

3.2.4　内容生成、展示与管理

虽然本文的重点是安全分析，但从整体研究路线看，内容生成模块同样具有重要作用。首先，它能够为虚假检测与审核实验提供可控样本来源，尤其是在公开数据集不完全覆盖目标场景时，平台内生成能力可以帮助快速构造研究样本。其次，生成模块可以与检测模块形成闭环验证流程，使系统同时具备“内容生成”“内容检测”“结果回流”的一体化演示能力。基于此，平台需要支持若干典型生成任务，如文生图、文生视频、图生视频以及与 Deepfake 相关的人脸替换、人脸动画和属性编辑等。

仅有生成与检测能力仍不足以支撑完整平台，因此系统还应具备结果展示与内容管理能力。对于检测结果，平台需要支持图像或视频预览、风险标签、置信度、建议说明等信息的统一展示；对于生成结果和检测记录，平台需要支持保存、查看和后续管理。内容管理模块的意义在于将离散的模型推理结果组织成可追踪、可对比的研究资料，这一点对实验分析和结果复核都十分重要。

综合来看，生成、检测、展示与管理需求共同构成了平台功能闭环。若缺少任何一个环节，系统都将更接近“单点能力演示”，而不是完整的研究平台。因此，功能需求分析必须从整体链路出发，而不能只围绕单个模型接口来展开。

3.3　非功能需求分析

3.3.1　可扩展性需求

本文课题处于 AIGC 安全研究快速演进的背景下，系统若仅能适配当前已接入的几个模型，其研究价值将受到较大限制。因此，可扩展性是平台设计中最重要的非功能需求之一。系统应允许后续继续接入新的图像检测模型、视频检测模型、安全审核接口和生成模型，并尽量减少对前端页面和已有模块的改动范围。

为满足这一需求，平台在设计上应采用模块化和接口化思路。前端尽可能围绕统一的数据结构渲染界面，后端则负责在不同能力之间做参数转换与结果标准化。这样，当未来引入新的检测方法时，只需在后端增加适配逻辑，而不必整体重构系统。对于毕业设计而言，这样的架构也更符合“可继续演进”的研究平台特征。

3.3.2　可维护性需求

系统涉及前端、后端、本地模型服务和外部接口多类组件，如果缺乏良好的可维护性设计，后续任何模块变动都可能影响整体稳定性。可维护性需求主要体现在三个方面。第一，职责清晰。前端负责交互与展示，后端负责调度与统一封装，模型服务负责推理逻辑，各层职责不应混淆。第二，数据结构统一。检测结果、生成结果和历史记录应使用相对稳定的数据模式，以减少页面层和业务层的耦合。第三，日志与错误处理可定位。系统在面对接口失败、模型超时、鉴权异常和输入不合法等情况时，应能够给出清晰提示，便于调试和排障。

如果一个平台只能在开发者本人熟悉的环境中偶然跑通，其工程价值是有限的。因此，系统需要通过清晰分层、统一接口和可定位错误处理保证基本可维护性，使平台能够在功能调整、模型替换和演示部署过程中保持稳定。

3.3.3　响应性能需求

内容安全分析平台虽然不是高并发商用系统，但仍需要满足基本的响应性能要求，否则将直接影响用户体验和实验效率。图像检测一般要求在较短时间内完成返回，以保证页面交互连贯；视频检测和视频生成则由于涉及更大数据量和异步任务，允许更长响应时间，但仍需要在平台层面对用户提供明确的进度反馈和状态说明。

因此，系统在设计时需要区分同步任务与异步任务。对于耗时较短的图像检测和图像审核，可采用同步请求直接返回结果；对于文生视频、图生视频及某些视频审核任务，则应通过后端代理层封装轮询逻辑，将复杂的异步流程转换为前端可接受的统一结果形式。提前区分两类任务能够避免前端页面直接承担复杂状态管理，也能降低长任务失败对用户体验的影响。

3.3.4　安全性与可部署性

作为 AIGC 安全分析平台，系统自身也需要满足基本安全性要求。首先，涉及外部接口调用时，密钥和鉴权信息不能暴露在前端。其次，本地模型服务和后端代理之间的调用关系应清晰可控，避免因接口配置混乱导致安全风险。再次，平台在处理用户上传内容时，应具备基本的输入检查与错误隔离能力，防止异常文件或不合规输入直接影响系统运行。

可部署性则强调平台不仅要能在本地开发环境中运行，还应能够迁移至实验室服务器或演示环境中进行展示。这要求系统在依赖管理、服务启动、端口规划和远程部署方式上具备一定规范性。结合本文当前原型进展，系统已采用前后端分离与模型服务独立运行的方式，因此可部署性也是总体设计中必须考虑的目标之一。

3.4　系统总体架构设计

3.4.1　总体架构设计思路

基于前述需求分析，本文将系统总体架构设计为前端展示层、后端代理层、模型推理与外部能力层三部分。之所以采用三层分离架构，而非将前端直接连接模型或将所有逻辑堆叠在单一服务中，主要基于以下考虑：其一，前端需要保持对多源能力的无感知，尽量以统一方式组织交互与结果展示；其二，后端需要集中处理鉴权封装、参数适配、结果标准化和异步调度；其三，本地模型与外部接口的接入方式差异明显，需要在系统边界上进行隔离。

这种三层结构本质上是一种面向研究原型的松耦合设计。它既能支持本地模型复现，又能保留调用外部能力的灵活性；既能满足实验中的方法对比需求，也能支撑功能扩展和部署演示。因而，该架构与本文“研究验证 + 工程实现”并重的课题定位是匹配的。

根据上述设计思路，本文平台总体架构如图 3.2 所示。该图并不强调某一个单独模型的内部结构，而是突出前端页面、后端代理、本地模型服务、外部能力接口与样本资源之间的协作关系。这样处理更符合本文系统设计型工作的重点，即说明多源能力如何被统一组织到同一安全分析平台中。

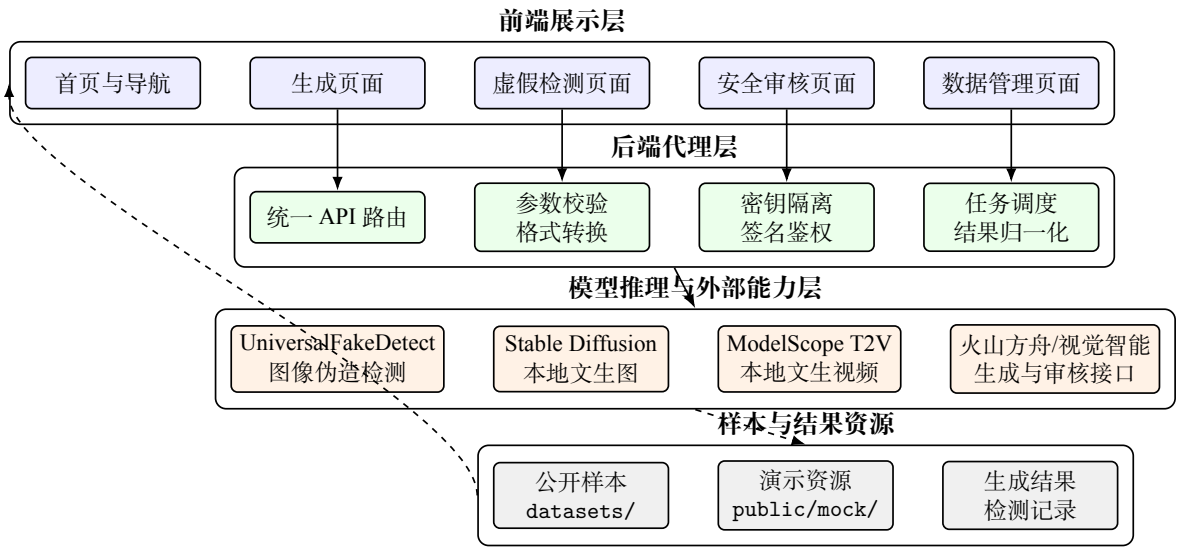

图 3.2: AIGC 安全分析平台总体架构

3.4.2　前端展示层设计

前端展示层是用户与平台交互的入口，主要承担内容上传、任务选择、检测触发、结果展示和历史查看等功能。从整体结构看，前端不负责算法推理与复杂业务编排，而是通过相对统一的组件结构组织不同页面。按照当前课题目标，前端可以划分为首

页、内容生成页、虚假检测页、不安全检测页和数据管理页等若干页面模块，各页面围绕具体业务场景提供相应操作入口。

为了提高系统一致性，前端展示层的设计原则是“统一入口、分任务展示、结果结构化”。即不同业务任务虽然在具体内容上存在差异，但用户都应遵循相近的操作流程：输入内容、选择任务、触发检测或生成、查看结果。这种统一交互模式能够降低系统复杂度，并增强平台的可演示性。

3.4.3　后端代理层设计

后端代理层是整个系统的核心枢纽。它位于前端与模型服务/外部接口之间，负责统一接收前端请求，并将其转发至正确的能力来源。更重要的是，该层承担了多源能力接入过程中的差异消解工作。例如，不同接口可能在鉴权方式、输入参数形式、异步处理机制和结果返回结构上存在明显不同，如果由前端直接处理这些差异，将导致页面逻辑复杂且难以维护。通过后端代理层统一封装后，前端只需面向统一业务接口即可。

在总体设计中，后端代理层需要支持三类核心任务：第一，统一请求入口，包括参数校验、内容格式转换和任务路由；第二，统一安全控制，包括密钥管理、签名计算和错误屏蔽；第三，统一结果结构，包括真假判断、风险标签、生成结果和历史记录的规范化表示。

3.4.4　模型推理与外部能力层设计

模型推理与外部能力层是系统真正执行检测与生成任务的能力来源，可进一步分为本地模型服务和外部接口服务两类。本地模型服务主要承担可控、可复现的研究任务，如本地图像虚假检测、本地文生图和本地文生视频等；外部接口服务则主要承担开放场景下的图像 AI 鉴别、视频 AI 鉴别以及图像/视频安全审核等任务。

这种“双来源能力层”设计与单一后端模型方案相比更符合本文课题实际。一方面，本地模型能够体现毕业设计在算法复现和自主部署方面的工作量；另一方面，外部接口能够弥补本地模型在多模态能力、视频审核能力和工程成熟度方面的不足。对平台而言，关键并不在于能力来源是否统一，而在于能否通过后端代理将这些异构能力组织为一个统一系统。

3.5　系统核心业务流程设计

3.5.1　内容检测流程设计

系统的基本检测流程可概括为“输入内容—任务选择—请求转发—结果解析—风险展示”。首先，用户在前端选择输入内容并指定任务类型，例如图像虚假检测、视频虚假检测、图像安全审核或视频安全审核。随后，前端将统一格式的请求发送给后

端代理层。后端根据任务类型和能力配置，将请求转发至对应的本地模型服务或外部接口，并在收到结果后完成字段标准化与状态归一化处理。最后，前端根据统一结果结构完成风险标签、置信度、原因说明和预览信息的展示。

为了使上述过程更加清晰，本文将内容检测流程抽象为图 3.3。该流程图体现了平台设计中的两个关键点：一是前端只面向统一任务入口，二是本地模型与外部接口均由后端代理层统一封装，最终以标准化结果返回前端展示。

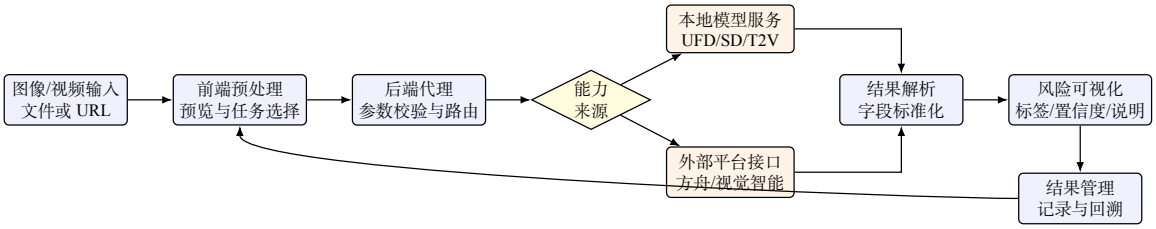

图 3.3: 内容安全检测业务流程

这一流程的关键在于“结果解析”环节。由于不同检测后端返回的数据结构差异较大，如果没有统一结果结构，前端就必须为每种能力编写单独渲染逻辑，系统复杂度会迅速增加。因此，在总体设计中，结果结构的统一性是业务流程顺畅运行的核心前提。

3.5.2　生成与闭环验证流程设计

除检测流程外，平台还需要支持“生成—检测—展示”的闭环验证流程。其基本逻辑是：用户先通过生成模块产生图像或视频内容，再将结果直接送入相应的检测模块，最后对生成样本的真假属性或安全属性进行分析。该流程在论文中的意义主要体现在两个方面。第一，它为实验样本构建提供平台内闭环来源，减少对外部数据的完全依赖。第二，它能够直观展示系统具备从生成到分析的完整链路，有利于体现平台整体性。

在总体设计层面，闭环验证流程并不要求所有生成结果都自动进入检测模块，而是要求平台在数据流上支持这种联动关系。也就是说，生成模块与检测模块之间应当能够共享输出数据或通过统一存储中转，从而避免重复上传和重复编码操作。

3.5.3　结果管理与追踪流程设计

为了支撑论文实验与系统演示，平台需要具备基本的结果管理与追踪流程。对于检测任务，应记录任务类型、输入来源、检测结论、风险标签、时间戳和必要的说明字段；对于生成任务，应记录生成类型、生成结果地址、生成时间和相关参数摘要。这样做的目的是将一次性的页面交互结果沉淀为可回溯的数据记录。

结果追踪流程的引入有助于解决两个问题：一是便于实验统计与人工核查，二是便于回看不同任务的示例结果。虽然当前平台尚不追求完整数据库化管理，但在总体设计中提前考虑结果管理机制，有利于模块扩展和功能完善。

3.6　模块划分与接口关系设计

3.6.1　功能模块划分

结合上述需求与业务流程，本文将平台划分为内容生成模块、虚假内容检测模块、不安全内容审核模块、数据管理模块和系统支撑模块五类。内容生成模块负责产出研究样本和演示素材；虚假内容检测模块负责判断内容真伪与 AI 生成属性；不安全内容审核模块负责识别内容风险类别与处置建议；数据管理模块负责结果查看、记录组织与后续分析支持；系统支撑模块则主要承担鉴权、代理、调度、日志和部署等功能。

这种模块划分方式的优点在于能够对应真实业务任务，便于用户理解系统结构，也便于在工程实现中分别维护生成、检测、审核和结果管理等功能。不同模块之间通过统一输入输出结构进行连接，既避免了功能耦合过重，也为后续接入新模型或扩展新任务保留了空间。

3.6.2　统一输入输出设计

在多源能力接入场景下，统一输入输出设计是降低系统复杂度的关键。对于输入层，平台应尽量将图像与视频内容统一抽象为“文件输入”与“链接输入”两种基本形式，再由后端根据任务需要完成 Base64 编码、URL 透传或其他格式转换。对于输出层，平台则应将不同后端返回的复杂结果归一化为若干核心字段，例如任务类型、判定结果、置信度、风险标签、说明文本、媒体预览地址等。

统一输入输出设计的重要价值在于，它使系统能够在不改变前端主流程的前提下替换底层能力。例如，当后续新增一个图像虚假检测模型时，只要该模型能够在后端层被适配为统一输出结构，前端页面就无需整体重写。这种设计思路也是平台可扩展性的直接体现。

根据当前平台的任务划分，本文将检测类结果抽象为表 3.1 所示的核心字段。该表并不对应某一个具体接口的原始返回，而是后端代理层归一化后的平台内部结果结构。通过这种方式，前端能够用相同的展示组件处理本地模型、多模态理解接口和内容审核接口返回的结果。

在风险等级映射上，本文采用相对克制的三档表达：低风险表示未发现明显问题或建议通过；中风险表示模型认为存在不确定因素，需要人工复审；高风险表示检测结果中存在较强伪造或违规信号，建议阻断或重点核查。这样设计的目的不是替代人工审核结论，而是把不同模型输出转换为一致的工程表达，使用户能够快速理解检测结果的严重程度。

表 3.1: 检测结果统一字段设计

字段类别	代表字段	设计说明
任务标识	taskType、mediaType	标记任务属于虚假检测或安全审核，以及输入媒介为图像或视频。
判定结论	isFake、safe、suggestion	虚假检测关注是否为 AI 生成或伪造；安全审核关注是否安全以及通过、复审、阻断等建议。
可信程度	confidence、riskScore	将模型分数或审核建议映射为 0 到 1 的置信度或 0 到 100 的风险分值，便于统一可视化。
风险解释	labels、reason、artifacts	保存风险标签、模型说明和可疑痕迹描述，提升检测结果的可解释性。
展示信息	previewUrl、model、details	记录预览资源、能力来源和任务细节，支持页面展示与实验回溯。

3.6.3 模块间协同关系

各功能模块并不是孤立运行的页面集合，而是围绕统一业务流程协同工作。内容生成模块负责产生图像或视频样本，虚假内容检测模块和不安全内容审核模块分别从真实性和安全性两个角度进行分析，数据管理模块则负责沉淀生成结果与检测记录。系统支撑模块贯穿整个流程，承担接口代理、鉴权封装、任务调度、错误处理和结果标准化等基础能力。

在该协同关系中，后端代理层是连接各模块的关键。前端页面只需按照任务类型提交统一请求，后端根据任务配置选择本地模型或外部接口，并将返回结果映射为统一字段。通过这种方式，生成、检测、审核和记录管理能够共享同一套输入输出规范，平台也具备继续扩展新任务的能力。

3.7 本章小结

本章围绕多模态 AIGC 安全分析平台的建设目标，对系统需求和总体设计进行了系统梳理。首先，从课题定位出发，明确了平台需要兼顾研究验证、工程演示和后续扩展三重目标；其次，围绕图像与视频输入、虚假内容检测、不安全内容审核、内容生成与结果管理等环节，对系统功能需求进行了分析；随后，从可扩展性、可维护性、响应性能以及安全性与可部署性等方面，进一步归纳了平台必须满足的非功能需求。

在此基础上，本文提出了由前端展示层、后端代理层和模型推理与外部能力层构成的三层总体架构，并分析了内容检测流程、闭环验证流程和结果追踪流程，完成了平台功能模块与统一输入输出结构的总体设计。通过这一章的分析可以看出，本文系统并非简单堆叠多个模型接口，而是在明确需求约束的前提下，构建了一个具有统一组织逻辑和扩展能力的研究原型平台。

第四章　关键模块与平台实现

第三章从需求和总体架构层面对平台进行了设计，明确了前端展示层、后端代理层、模型推理与外部能力层之间的职责边界。在这一设计基础上，平台实现的关键不只是把各个模型或接口调通，而是要把多源模型能力、外部服务和前端交互组织为稳定的业务流程。为此，系统需要解决异构接口接入、输入输出标准化、任务调度、错误处理、风险展示和部署运行等问题，使图像检测、视频检测、安全审核和内容生成能够在同一平台中协同工作。

4.1　多源检测框架实现

4.1.1　统一能力组织思路

本文平台面临的一个核心问题是，系统所接入的能力来源并不统一。一部分能力来自本地复现模型，例如 UniversalFakeDetect、Stable Diffusion 和 ModelScope Text-to-Video；另一部分能力来自外部平台接口，例如火山引擎视觉智能接口和方舟多模态理解接口。若让前端直接面向这些异构能力，将会面临参数格式不一致、鉴权方式不同、返回结构差异较大和异步机制复杂等问题。因此，系统在实现上首先引入了统一能力组织思路，即由后端代理层将多源能力封装为统一业务接口，再由前端按任务类型进行调用。

这一实现思路对应到代码层面，主要表现为后端服务将所有核心能力组织为检测类接口与生成类接口两大类。其中，检测类接口包括图像 AI 生成检测、视频 AI 生成检测、图像安全审核、视频安全审核以及本地图像伪造检测；生成类接口包括人脸替换、人脸动画、属性编辑、文生图、本地文生图、文生视频、本地文生视频和图生视频等。通过这样的组织方式，前端并不直接感知某个任务究竟来自本地模型还是外部平台，而只需要知道当前调用的是哪一类业务接口。

从系统实现角度看，这种统一封装的意义主要有三点。第一，它降低了前端的复杂度，使页面组件可以围绕“任务逻辑”而不是“能力来源”设计。第二，它为新增模型或更换接口提供了缓冲层，减少改动范围。第三，它使不同能力的结果可以在后端完成标准化处理，为风险展示和实验统计提供统一数据结构。

4.1.2　输入参数与结果结构标准化

多源能力的统一接入不仅体现在接口数量的组织上，更体现在输入参数和输出结果的标准化处理上。对于输入层，平台主要围绕图像与视频两类媒体设计统一请求模式。以图像相关任务为例，后端统一接收 `imageUrl` 或 `imageBase64` 两种形式；视频相关任务则统一接收 `videoUrl` 或 `videoBase64`。这种设计能够同时支持文件输入与链接输入，也便于前端在不同页面之间复用上传、预览与提交逻辑。

在输出层，不同后端能力原生返回的数据结构差异较大。例如，本地检测模型更倾向于返回标签、概率与辅助信息；多模态理解接口则常常返回自然语言或嵌套结构化对象。为避免前端为每种能力单独编写渲染逻辑，系统在后端实现中对这些结果进行了归一化处理。以虚假内容检测为例，平台最终统一关注真假结论、置信度、模型名称、原因说明和辅助展示信息；以不安全内容审核为例，平台统一关注安全与否、建议处置级别、风险标签以及说明性文本。这样一来，前端页面便可以围绕统一字段完成风险标签、进度条、说明卡片和预览区域的展示。

值得注意的是，多模态大模型接口并不总是严格返回纯 JSON 文本，因此系统在实现中还增加了结构提取与容错逻辑。对于图像与视频理解结果，后端会先尝试从模型输出中匹配结构化对象，再执行解析和字段映射。虽然这种方式在工程上增加了一层处理，但它显著提升了结果格式的稳定性，也使大模型接口更适合被纳入一个面向用户的平台中。

多源检测结果的标准化流程如图 4.1 所示。该流程体现了本文平台实现中的一个核心原则：前端只面向统一业务语义，后端负责吸收不同模型和接口之间的格式差异。这样既能降低页面复杂度，也能在后续接入新模型时保持已有交互流程稳定。

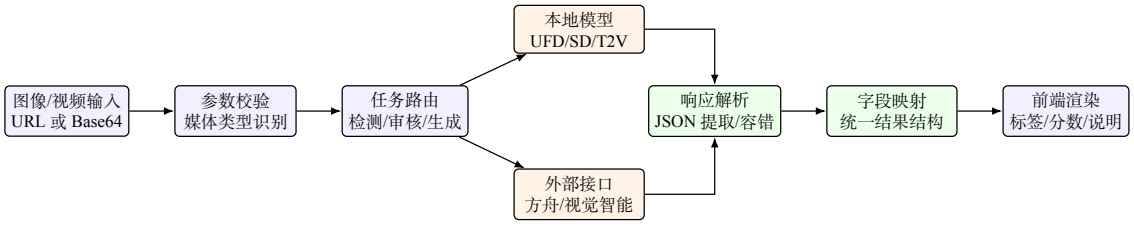

图 4.1: 多源检测结果标准化处理流程

4.2　图像虚假内容检测模块实现

4.2.1　本地检测模型接入实现

图像虚假内容检测模块首先接入了本地部署的 UniversalFakeDetect 模型，用作平台中的自主检测能力和研究基线。该模型服务通过 Python 接口封装后运行在独立端口，对外提供标准 HTTP 接口。为了让前端无需直接访问 Python 服务，Node.js 后端对其进行了再次代理封装：前端只需访问统一的业务接口，后端再根据请求内容将 `imageUrl` 或 `imageBase64` 转换为本地模型所需的字段形式，并转发至本地推理服务。

这种二次代理的实现方式具有明显优势。一方面，它避免了前端同时管理多个服务地址的问题，使前端始终只面向后端代理层。另一方面，后端可以对本地模型返回结果进行错误检查与结构统一。例如，当本地服务不可达、返回非 JSON 结果或状态码异常时，后端可以将错误信息转换为平台层面可理解的提示，从而避免用户面对底层推理服务的原始报错。

从实现效果上看，本地检测模型的接入使平台具备了“可控、可复现、可离线研究”的能力。它并不依赖外部网络环境，也更适合作为论文实验中的基线方法。与此同时，本文并未将其设计为平台唯一的图像检测方案，而是将其与外部多模态检测能力并列放置，从而更符合真实应用中“多源并存”的系统构型。

本地检测链路可进一步拆分为四个步骤。首先，Python 服务启动时读取权重路径、阈值和模型架构配置，并在 `auto` 模式下根据全连接层权重维度推断实际使用的视觉编码器。其次，服务接收 `image_base64` 或 `image_url` 输入，将远程图片下载或 Base64 内容解码为原始图像字节。再次，推理函数完成图像预处理、视觉特征提取和分类头前向计算，得到 0 到 1 之间的伪造分数。最后，服务根据默认阈值 0.5 将分数映射为 `is_ai_generated`，并返回模型架构、阈值、分数和说明文本。Node.js 代理层在收到上述结果后，再将其转化为前端统一的 `isFake`、`confidence`、`model` 和 `details` 字段。

这种实现方式的优点是把“模型推理”和“平台业务”分开处理：Python 服务只关注检测模型能否稳定推理，Node.js 后端只关注请求转发、错误屏蔽和结果结构统一。两者之间通过 HTTP 接口连接，使模型替换与页面迭代互不干扰。

4.2.2　外部图像 AI 鉴别接口接入实现

除本地模型外，平台还接入了基于多模态理解能力的图像 AI 鉴别接口。其核心实现思路是：由后端将输入图像与固定判定提示词组织为统一消息体，提交至支持视觉输入的模型接入点，再从返回结果中抽取真假判断、置信度和原因说明。与传统分类模型不同，这类接口本质上是将图像检测任务转化为“视觉输入 + 自然语言约束 + 结构化输出”的推理过程。

从工程实现角度看，图像 AI 鉴别接口的接入重点不在于算法本身，而在于提示词设计与结果稳定化处理。为此，后端对模型输出格式进行了严格约束，要求其仅返回包含真假字段、置信度字段和原因字段的结构化对象，并将推理温度控制在较低水平，以减少回答波动。对于模型偶尔返回自然语言解释或额外文本的情况，后端再通过正则提取和 JSON 解析实现结果归一化。

该模块与本地模型共同构成了图像虚假检测的双后端方案：前者强调研究可控性和自主部署，后者强调开放场景下的适应性与工程接入效率。前端页面在此基础上提供后端切换选项，使平台不仅能够完成检测任务，也能够为不同方法的实验对比提供直接支撑。

在结果解释方面，外部图像 AI 鉴别接口返回的 `reason` 字段会被前端展示为可

疑痕迹说明；本地 UniversalFakeDetect 返回的模型架构、阈值和判定信息则被组织为辅助说明。二者虽然来源不同，但最终都进入相同的展示区域。这种设计使用户能够在同一页面中比较“本地判别分数”和“多模态解释文本”，也体现了平台对不同检测范式的兼容能力。

图 4.2 展示了图像虚假检测模块的页面形态。页面左侧用于输入图片并选择检测方式，右侧用于展示检测步骤、当前状态和最终结果。该页面设计对应了本文“统一入口、分任务展示、结果结构化”的前端原则，使本地模型和外部接口的检测结果能够在同一界面中呈现。

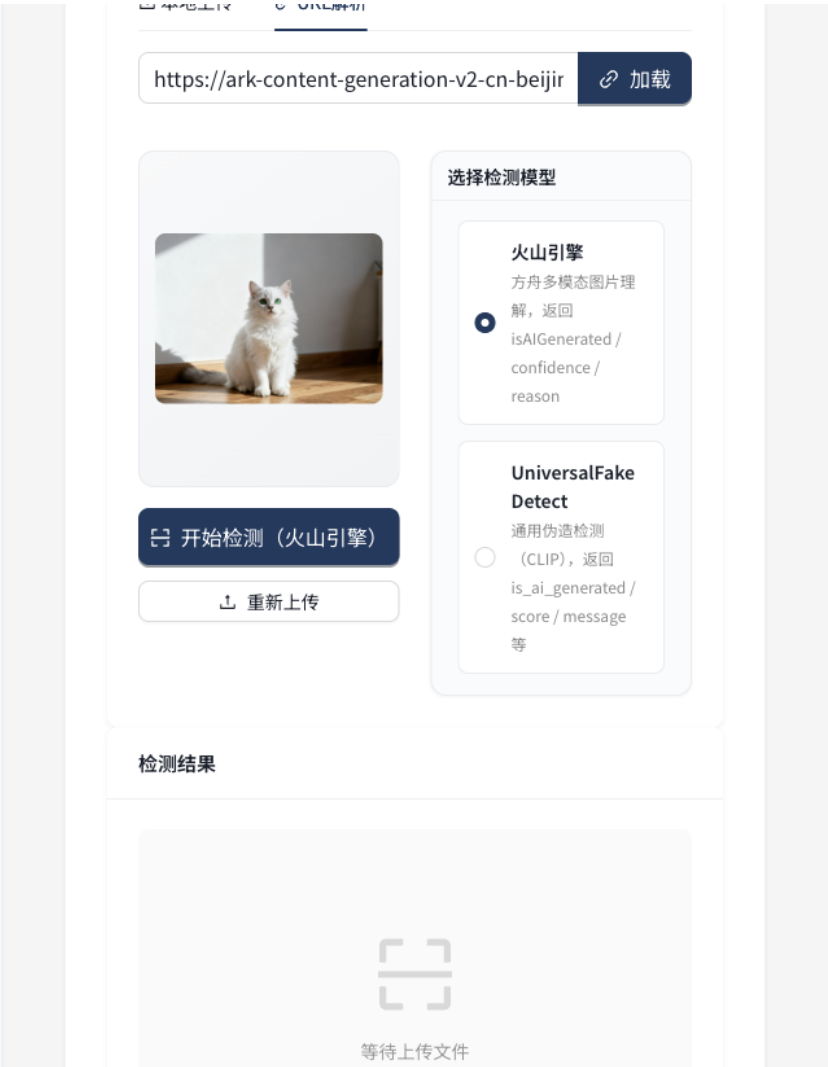

图 4.2: 图像虚假内容检测模块界面

4.3　视频虚假内容检测模块实现

4.3.1　视频理解接口接入实现

与图像检测相比，视频真假检测的实现复杂度更高。一方面，视频数据体量更大，上传与传输成本更高；另一方面，当前本地通用视频检测模型的复现与部署成本也明显高于图像场景。基于这一现实条件，平台当前主要采用多模态视频理解接口作为视频 AI 生成检测的主实现方式。具体而言，后端统一接收前端提交的视频 URL 或视频 Base64 内容，将其组织为 `video_url` 类型输入，再与固定的视频真假判定提示词一同发送给多模态理解接口。

这一实现方案的关键不在于简单调用接口，而在于将外部能力转化为平台可用的稳定功能。为此，后端在请求构造时对视频输入格式进行了统一处理，对返回内容执行结构提取和字段映射，并根据置信度范围构造适合前端展示的结论文案。例如，在系统内部，模型原始输出会被进一步整理为是否为伪造、置信度值、模型名称、辅助说明和展示信息等字段，以便前端页面直接渲染。

从系统整体看，这种实现方式反映了本文平台“能力优先、统一封装”的工程策略。虽然当前版本尚未接入本地视频检测模型，但平台架构已经预留了对应位置，使未来若引入训练自由或专用视频检测模型，也可按与图像检测相同的方式纳入统一代理框架。

4.3.2　视频检测结果结构化实现

视频检测结果的结构化处理是该模块实现中的另一个重点。由于视频真假判别往往包含更强的不确定性，平台在结果表达上不能仅停留在简单的真假标签，而应尽量体现模型判断的置信程度和结论层级。基于这一考虑，系统在后端对视频检测输出进一步组织为“真假结论 + 置信度 + 模型名称 + 细节说明”的结构，并在前端以标签、进度条和文本解释等方式进行展示。

这种结构化表达具有两方面作用。首先，它使用户能够直观看到模型对当前视频的判断强弱，而不是被一个绝对化结论所误导。其次，它为不同视频样本之间的对比提供了统一字段基础，使结果统计和人工复核更容易实现。

4.4　不安全内容检测模块实现

4.4.1　图像安全审核模块实现

图像安全审核模块的核心目标是识别图像中是否存在暴力、色情、仇恨、敏感符号或其他违规风险内容，并输出风险标签与处置建议。平台在实现上采用与图像 AI 鉴别相近的技术路径，即通过后端向多模态理解接口发送图像输入和安全审核提示词，再从模型回复中抽取安全结论、建议级别、标签集合和原因说明。

这一模块与虚假内容检测模块的差别主要体现在结果结构上。真假检测关注的是“是否由 AI 生成”，而安全审核关注的是“是否应当通过、复审或阻断”。因此，系统在后端解析结果时，不再将输出映射为真假标签，而是映射为安全状态、风险标签和处置建议，并进一步为前端展示转换为低、中、高不同风险层级。这样的实现方式使平台能够在统一 UI 框架下展示两类不同任务的结果，同时保持业务含义上的清晰区分。

4.4.2　视频安全审核模块实现

视频安全审核模块的实现逻辑与图像审核类似，但在输入组织和结果呈现上更强调视频语义整体性。后端统一接收视频链接或视频 Base64 编码，将其与安全审核提示词一起发送至支持视频理解的模型接口，并在响应后对安全结论、建议级别和标签信息进行标准化处理。前端在展示时则重点突出风险等级和建议说明，以便用户快速判断该视频是否需要人工复核。

在工程实现上，视频安全审核模块还体现了一个重要特点，即其结果不仅服务于页面展示，也为风险分级逻辑提供基础数据。审核模块与全局风险展示模块紧密配合：后端负责产出标准字段，前端负责将这些字段转化为易理解的可视化元素。这种分工方式使系统结构更清晰，也更便于后续统一调整风险分级策略。

为了使图像审核和视频审核结果在页面上保持一致，系统将外部接口中的审核建议字段映射为平台风险等级：`pass` 对应低风险，`review` 对应中风险，`block` 对应高风险；同时将风险标签字段映射为前端标签。表 4.1 给出了当前平台采用的风险映射方式。

表 4.1: 安全审核结果风险映射

接口建议	平台风险等级	页面展示与处理含义
`pass`	低风险	未发现明显违规内容，页面展示为可通过状态，仍保留模型说明用于回溯。
`review`	中风险	存在不确定或边界风险，页面提示建议人工复审，并展示风险标签和原因。
`block`	高风险	存在较明确违规或危险信号，页面展示为高风险并建议阻断或重点核查。

4.5　样本生成与内容管理模块实现

4.5.1　生成模块实现

为了形成“生成—检测—分析”的闭环研究平台，系统实现了两类生成能力：一类是与 Deepfake 相关的人脸替换、人脸动画和属性编辑；另一类是通用场景下的文

生图、文生视频和图生视频。前者主要通过火山视觉智能接口和方舟图生视频接口实现，后者则由外部生成接口与本地部署模型共同支持。

在人脸相关生成任务中，系统通过前端表单组织输入内容，并在后端完成图像编码、参数映射和接口调用。人脸替换任务重点处理双图输入与顺序匹配问题；人脸动画任务重点处理首帧图像与文本驱动的联合输入；属性编辑任务则重点支持文本指令与图像内容的组合。通用生成任务中，文生图既支持外部文生图接口，也支持本地 Stable Diffusion 服务；文生视频既支持外部文本到视频接口，也支持本地 ModelScope Text-to-Video 服务；图生视频则通过参考图与文本提示的联合输入实现动态内容生成。

这些生成模块的作用主要体现在两个方面。第一，它们使平台具备了多模态内容生产能力，可为检测模块构造样本。第二，它们验证了平台并不是一个孤立的“内容审查器”，而是一个可用于研究 AIGC 全链路安全问题的原型系统。

图 4.3 展示了平台文生图模块的运行界面。该截图对应“输入提示词—选择生成模型—返回媒体结果”的典型生成流程，能够直观说明系统已经将外部生成能力封装为可交互的前端功能，而不是停留在后端接口调用层面。

图 4.3: 文生图生成结果展示界面

4.5.2　数据管理模块现状与实现方式

数据管理模块用于承接生成结果与检测记录的浏览、回看和后续使用。从当前实现情况看，平台已经具备数据管理页面骨架、内容列表展示逻辑和检测记录展示逻

辑，但完整的保存、检索和导出功能仍在持续完善中。换言之，该模块在当前版本中更多承担“研究结果组织入口”的角色，而非一个完整的生产级资产管理系统。

当前数据管理模块已经能够作为生成结果和检测记录的统一入口，但尚未扩展为完整的生产级资产管理系统。该设计符合研究原型平台的定位：优先保证生成、检测、审核和结果回看的主流程可运行，同时为后续检索、导出和批量统计功能预留接口。

4.6　风险分级与可视化展示实现

平台在实现上并未将检测结果仅仅停留在接口返回层，而是进一步构建了统一的风险展示方式。对于虚假内容检测，前端主要通过真假标签、置信度进度条、模型名称和原因说明展示分析结果；对于不安全内容审核，则通过风险等级、建议级别、风险标签和说明性文本呈现审核判断。通过这种方式，不同任务虽然共享平台框架，但仍能突出各自业务含义。

在可视化实现上，平台前端采用分任务页面组织方式，将生成结果预览、检测结论和辅助说明放在同一页面中展示，以减少用户在不同页面间切换的成本。对于图像任务，页面可直接展示原图与生成图；对于视频任务，页面则以视频播放区域、文字说明和风险标签结合的方式完成展示。此外，前端还通过统一配色、标签体系和响应式布局增强页面一致性，使平台更符合教学展示和系统演示场景。

风险分级与可视化展示模块的实现价值在于，它将底层模型推理结果转化为能够被用户快速理解的信息表达形式。对于毕业论文而言，这也是系统从“模型集合”转变为“平台系统”的关键一步。

4.7　前后端平台开发与部署实现

4.7.1　前端页面与交互实现

前端部分采用 React、TypeScript、Vite 和 Ant Design 构建。根据当前代码结构，系统已经形成首页、Deepfake 生成页、通用生成页、虚假内容检测页、不安全内容检测页和数据管理页六个核心页面。路由层按业务功能进行划分，使不同页面既能独立完成任务，又保持统一导航入口。

在交互层面，前端主要围绕表单输入、文件上传、结果预览和状态提示展开。对于生成和检测任务，页面通常包含输入区、模型或任务选择区、执行按钮和结果展示区。对于结果较耗时的任务，前端还通过加载状态、提示信息和轮询等待结果等方式改善用户体验。与此同时，前端通过统一的接口访问封装，将所有请求都指向后端代理层，从而避免在页面组件中散落不同服务地址与鉴权逻辑。

平台首页与模块导航界面如图 3.1 所示。首页并不直接承担模型推理任务，而是用于组织生成、检测和内容管理等功能入口，使用户能够从统一入口进入不同安全分

析流程。这种页面组织方式能够降低用户理解成本，并保持各功能模块之间的入口一致性。

当前前端页面与核心职责的对应关系如表 4.2 所示。该表反映出本文平台并非单页接口演示，而是围绕生成、检测、审核和结果管理形成了相对完整的功能分区。

表 4.2: 前端页面模块与职责

页面模块	主要输入	核心职责
首页与导航页	无或少量演示入口	展示平台功能分区，引导用户进入生成、检测和数据管理流程。
Deepfake 生成页	源人脸、目标图像、驱动描述或编辑指令	支持人脸替换、人脸动画和属性编辑等典型深度伪造生成任务。
通用生成页	文本提示词、参考图像和生成参数	支持文生图、文生视频、图生视频以及本地生成服务调用。
虚假检测页	图像/视频文件或 URL	提供本地模型与外部接口两类真假检测入口，并展示置信度和原因说明。
不安全检测页	图像/视频文件或 URL	对内容进行安全审核，输出风险等级、风险标签和处置建议。
数据管理页	检测记录和生成结果	组织平台输出结果，支持实验回看和样本管理扩展。

4.7.2 后端代理与任务调度实现

后端服务基于 Node.js 和 Express 实现，是整个平台的能力汇聚中心。它在实现上主要承担四类职责：一是统一接收前端请求并按任务路由至不同能力；二是处理外部接口鉴权，包括 Bearer Token 和 HMAC-SHA256 签名两种主要模式；三是对多模态大模型返回结果进行结构提取与统一封装；四是对异步生成任务执行轮询调度，使前端能够以相对简洁的同步调用方式获得最终结果。

其中，异步任务封装是后端实现中的关键点之一。以视频生成任务为例，外部平台通常采用“提交任务—轮询查询—返回结果”的模式，如果前端直接处理这些步骤，将显著增加页面逻辑复杂度。后端通过统一封装轮询逻辑，将复杂异步流程收敛为单一业务接口，从而大幅简化前端实现，也使任务状态、超时处理和错误提示能够在后端集中管理。

后端代理层对同步检测任务和异步生成任务的处理流程如图 4.4 所示。对于图像检测等同步任务，后端主要完成参数转换、接口调用和结果归一化；对于视频生成等异步任务，后端还需要承担任务创建、轮询查询和超时处理。通过这种封装，前端能够以统一业务接口调用不同能力，系统也因此具备较好的可维护性和扩展性。

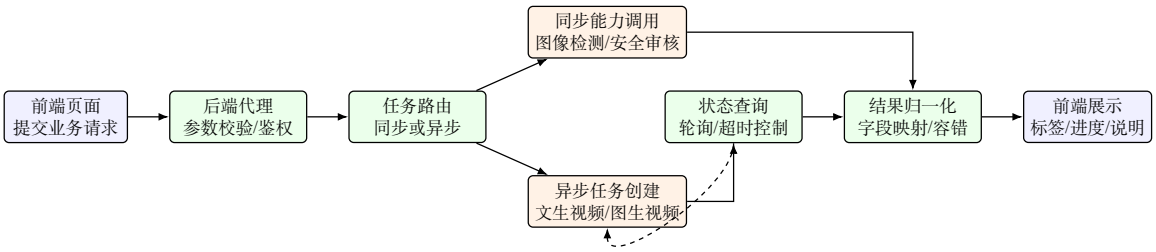

图 4.4: 后端代理层任务调度与结果归一化流程

4.7.3　模型服务部署实现

本地模型服务采用独立进程方式运行，其中图像虚假检测、本地文生图和本地文生视频分别封装为独立服务，并通过不同端口提供推理接口。结合当前项目进展，这些服务与后端代理进程共同部署在实验室服务器中，由前端通过后端统一访问。平台整体采用前后端分离部署方式：前端构建后作为静态页面运行，后端代理与本地模型服务作为独立进程驻留运行。

这种部署方式的优点在于结构清晰、便于调试和扩展。本地模型服务可以按需单独重启和替换，后端代理则负责维持稳定对外接口。由于前端、后端和模型服务之间的边界较为明确，系统运行中出现问题时也更容易定位。尽管当前系统仍然存在视频模型资源开销较大、数据管理能力尚待完善等问题，但从整体上看，该部署方案已经能够支撑平台的核心功能运行。

4.8　本章小结

本章围绕平台关键模块梳理了具体实现方式。首先，围绕多源检测框架，介绍了系统如何通过后端代理实现本地模型与外部接口的统一接入，以及如何完成输入参数和结果结构的标准化处理。随后，分别说明了图像虚假内容检测、视频虚假内容检测、不安全内容审核、样本生成与结果管理等模块的实现逻辑，并分析了风险分级与可视化展示在平台中的作用。

在工程实现层面，本章还总结了前端页面组织、后端代理与任务调度以及本地模型服务部署的主要做法，体现了平台从需求分析到具体落地的完整链路。可以看到，本文系统的特点并不在于某一个单独模型本身，而在于通过统一组织与模块化实现，使多类能力在同一平台中协同工作。

第五章　实验设计与结果分析

实验验证的目标是检验平台是否能够真实运行、各类能力是否能够协同工作，以及当前方案的优势与不足分别体现在哪里。围绕这一目标，本章从实验环境、样本构建、图像检测、视频检测、安全审核和系统可用性等方面对平台进行验证与分析。

本文的实验部分根据当前系统成熟度进行取舍。考虑到本地视频检测模型尚未完全补齐、样本规模仍在扩充，同时整篇论文需要控制在合理篇幅内，本文不追求对所有任务给出大规模、全覆盖的定量结果，而是采用“图像虚假检测以定量评估框架和验证样本为主，视频与不安全内容检测以功能验证和案例分析为主，系统性能以可用性分析为主”的实验策略。这样既能保证实验内容与当前平台完成度保持一致，也能突出本文最具代表性的系统能力。

5.1　实验目标与取舍原则

结合本文平台的实现情况，本章实验主要服务于以下三个目的。第一，验证图像与视频检测链路能够真实跑通，平台不仅具备页面交互能力，也能够完成从输入到结果展示的完整闭环。第二，分析本地模型与外部接口在不同任务中的适用差异，为方法扩展和实验优化提供依据。第三，评估当前平台在研究验证和系统演示场景下的可用性，包括任务响应特征、风险展示效果和系统组织方式等。

在实验取舍方面，本文优先保留三类最有代表性的验证内容。其一，是图像虚假内容检测实验。该任务既有本地模型，也有外部多模态接口，且仓库中已经包含可用于验证的图像测试样本，因此最适合作为平台检测能力的核心观察对象。其二，是视频虚假检测与不安全内容审核实验。虽然这一部分当前难以形成与图像任务同等规模的标准数据集对比，但其功能链路完整，能够体现平台对多模态任务的支持能力。其三，是系统性能与可用性分析。本文课题本质上是一个多源能力集成平台，因此系统在任务组织、前后端配合和同步/异步流程处理方面的表现，同样构成实验评价的重要部分。

与之对应，本文暂不将大规模跨数据集、跨模型的综合排行榜式对比作为实验重点，原因主要有两点。一方面，当前平台阶段更强调闭环实现与方法接入，尚未完成所有本地检测模型的扩展复现；另一方面，来源不完全一致的对比数值容易削弱实验结论的可信度。因此，实验设计更强调真实、可复验和能够反映系统特征，而不是追求形式上的指标堆叠。

5.2 实验环境与评价指标

5.2.1 实验环境

本文实验主要在校内实验室服务器环境下完成，平台采用前后端分离与模型服务独立运行的部署方式。前端页面通过静态构建方式部署并提供统一访问入口，后端代理服务负责接收前端请求并转发至本地模型服务或外部接口，本地模型服务则分别承担图像虚假检测、本地文生图和本地文生视频等推理任务。根据当前平台部署结构，前端静态页面运行于独立端口，后端代理服务和本地模型服务分别运行于不同端口并由独立进程管理。

从软件栈看，前端基于 React、TypeScript、Vite 和 Ant Design 构建；后端基于 Node.js 与 Express 实现；本地推理服务基于 Python、FastAPI 与 PyTorch 封装。外部能力主要来自图像与视频理解接口、图像与视频生成接口以及视觉智能类服务。这样的实验环境既反映了本文原型平台的真实部署方式，也为不同能力的统一接入提供了基础。

本文实验不以评估底层硬件极限性能为目标，而是重点验证当前平台方案在研究和演示场景中的可行性。因此，实验更关注功能链路是否完整、结果表示是否稳定以及不同能力在统一平台中的适配情况，而不是对底层 GPU 吞吐能力进行专门测试。

5.2.2 评价指标

对于图像虚假内容检测任务，本文采用分类任务中常见的准确率、精确率、召回率和 F1 值作为主要评价指标。其定义如下：

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{5.1}$$

$$Precision = \frac{TP}{TP + FP} \tag{5.2}$$

$$Recall = \frac{TP}{TP + FN} \tag{5.3}$$

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall} \tag{5.4}$$

其中，TP 表示将伪造样本正确识别为伪造的数量，TN 表示将真实样本正确识别为真实的数量，FP 表示将真实样本误判为伪造的数量，FN 表示将伪造样本误判为真实的数量。上述指标适合用于衡量图像检测模型在二分类任务中的整体表现，也适合用于不同检测方法之间的对比。

对于视频检测与不安全内容审核任务，考虑到当前阶段更强调平台可用性验证和案例分析，因此本章不强行引入不完全匹配的数值指标，而主要从以下角度进行评

价：第一，任务链路是否能够完整跑通；第二，返回结果是否具有结构化和可解释性；第三，平台能否将检测或审核结论稳定映射为统一的风险展示形式。这样的评价方式更符合当前平台进展，也能避免在数据基础不足的情况下形成不可靠数值。

5.3　数据集与测试样本构建

5.3.1　图像真假检测样本

结合当前仓库内容与平台进展，本文图像真假检测实验主要采用两类样本来源。第一类是仓库中已经整理完成的 ProGAN 测试样本集，当前共包含真实图像 200 张、伪造图像 200 张，总计 400 张样本。该数据集的优点在于标签明确、结构清晰，适合用于验证图像虚假检测接口与本地模型服务的基本可用性。第二类是平台生成与展示过程中使用的样例图像，包括平台内部文生图结果、人脸编辑结果以及若干代表性示例图片。这类样本虽然不用于严格定量统计，但有助于观察系统在开放场景输入下的判定表现。

从实验设计角度看，ProGAN 测试样本适合作为当前阶段的“基线验证集”，其目的不是覆盖所有最新扩散模型，而是确认平台中的图像虚假检测链路能够在明确标签数据上稳定工作。与此同时，开放场景样例图像则用于弥补标准集与真实业务场景之间的差距，使实验分析能够同时覆盖结构化测试与案例观察两个维度。

在实际评测中，本文进一步从 ProGAN 测试集中按真实与伪造两类各取 100 张构成平衡的 `progan_mini` 子集，用于验证 UniversalFakeDetect 本地模型在当前部署环境中的推理链路。选择子集评测的原因在于：一方面，该子集已经能够覆盖真实/伪造两类基本判别场景；另一方面，它更适合作为毕业论文阶段的快速回归验证集，便于在模型服务、后端代理和前端页面调整后重复确认系统是否正常工作。

表 5.1: 当前阶段图像真假检测样本构成

样本来源	类别	数量
ProGAN 测试集	真实图像	200
ProGAN 测试集	伪造图像	200
平台样例与生成结果	开放场景补充样本	若干

5.3.2　视频与安全审核样本

与图像任务相比，视频与不安全内容审核实验当前更适合采用“代表性样例 + 功能链路验证”的方式进行。仓库中已经包含若干图像与视频样例，例如普通自然场景图像、明显风险场景图像、短视频样例以及生成或伪造相关样例素材。这些内容能够覆盖安全图像、风险图像、普通视频、疑似生成视频等几种典型输入类型，为验证平台在不同页面和不同任务下的行为提供了基础。

此外，平台自身具备内容生成能力，因此实验样本还可以来自平台内部生成结果。部分样本来源于公开数据和仓库素材，部分样本来源于平台内部生成结果，两者共同构成当前阶段的实验验证基础，也体现了平台“生成—检测—展示”的闭环特点。

5.3.3　实验样本组织策略

为了使实验部分保持紧凑且具有代表性，本文对样本组织采取了分层策略。对于能够形成明确标签和定量指标的任务，如图像虚假内容检测，优先使用结构化样本集进行评估；对于当前难以形成统一标准集、但平台链路已经完整的任务，如视频真假检测与内容安全审核，则采用代表性案例验证方式。这样的组织策略既体现了实验设计的针对性，也符合本科毕业论文在有限篇幅内突出核心成果的写作要求。

5.4　图像虚假内容检测实验与分析

5.4.1　实验目的与方案

图像虚假内容检测实验主要验证两个问题。第一，本地检测模型接入后，平台是否能够在结构化图像样本上完成稳定判断；第二，外部多模态图像 AI 鉴别接口在开放场景中能否补充本地模型在解释性和泛化性方面的不足。围绕这两个问题，本文将图像实验划分为“本地模型基线验证”和“开放场景样例分析”两部分。

在本地模型基线验证部分，实验使用 ProGAN 测试样本集，重点考察本地图像检测接口在统一数据集上的可用性以及准确率、精确率、召回率和 F1 值等指标的适用性。由于当前阶段论文重点仍然是系统平台实现与实验框架构建，本文不将这一部分展开为多轮大规模重复实验，而是将其作为补充定量对比的标准入口。在开放场景样例分析部分，则使用平台生成图片、示例图片和典型场景图片，观察本地检测模型与外部多模态接口在结果表达与适用范围上的差异。

5.4.2　阶段性结果分析

本地图像虚假检测模块在 `progan_mini` 子集上的阶段性结果如表 5.2 所示。结果文件由仓库中的 `results_mini/acc0.txt` 和 `results_mini/ap.txt` 保存，其中 `acc0` 表示以 0.5 为阈值时的真实类准确率、伪造类准确率和总体准确率，AP 表示平均精度。可以看到，在该平衡子集上，本地模型能够稳定区分 ProGAN 真实样本与伪造样本，说明模型权重、预处理流程、阈值设置和评测脚本在当前环境下能够正常工作。

表 5.2: UniversalFakeDetect 在 ProGAN mini 子集上的阶段性结果

评测集	真实样本	伪造样本	真实类准确率	伪造类准确率	总体准确率	AP
progan_mini	100	100	100.00%	100.00%	100.00%	100.00%

需要说明的是，上述结果主要用于验证本地模型在已知 ProGAN 分布上的可用性，不能直接等同于平台在所有生成模型上的泛化能力。结合第二章的分析，当前生成模型已从 GAN 扩展到扩散模型和多模态视频生成模型，因此仅凭 ProGAN 结果并不足以证明检测器在开放域场景中始终可靠。本文将该结果定位为“本地基线链路验证”，其价值在于证明平台已经具备可复验的本地检测入口，未来可继续扩展到扩散模型、压缩扰动样本和真实业务样本。

与本地模型相比，外部多模态图像 AI 鉴别接口更适合承担开放场景分析任务。其优势不在于替代本地基线模型，而在于能够提供相对灵活的自然语言解释和对复杂场景的适配能力。从平台使用体验上看，外部接口与本地模型在图像任务中的关系更接近互补而非竞争：前者更适合开放域案例分析和多模态推理，后者更适合作为稳定、可控的研究基线。

图 5.1 展示了平台图像检测结果页面。结果区域将模型结论、置信度、模型来源和原因说明集中展示，说明后端代理返回的结构化字段能够被前端稳定渲染。该案例验证的重点不是单张图像的结论本身，而是“上传输入—调用检测后端—解析返回—可视化展示”的完整链路。

综合分析可知，图像虚假检测实验已经体现出本文平台方案的一个关键优势，即它并不依赖单一检测路径，而是通过统一代理层将“可控的本地方法”和“灵活的外部能力”组织到同一平台中。随着更多图像检测模型接入，平台的研究深度还可以进一步增强。

5.5　视频检测与安全审核验证

5.5.1　视频真假检测验证

视频真假检测实验的重点不在于形成大规模数字对比，而在于验证平台是否能够完成视频输入、统一转发、结构化结果返回和前端展示的完整链路。结合当前平台进展，视频真假检测主要通过多模态视频理解接口实现。实验中，用户既可以输入视频链接，也可以上传本地短视频，由后端统一转换为适配接口的形式，再返回真假结论、置信度与文本说明。

从阶段性结果来看，平台已经能够较稳定地完成视频真假检测链路，前端也能够将结果以风险标签、置信度和说明文本的形式呈现。这说明，尽管当前尚未在本地部署完整视频伪造检测模型，平台在视频任务上的基础能力已经建立。对毕业设计而言，这样的结果是有价值的，因为它证明了系统并非只支持图像任务，而是已经具备面向多模态内容的统一分析能力。

图 5.1: 图像虚假内容检测结果展示

5.5.2 不安全内容审核验证

不安全内容审核实验同样以链路完整性和结果可解释性为主要考察目标。对图像审核任务而言，平台能够对输入图像返回安全与否、风险标签、建议级别和说明性原因；对视频审核任务而言，平台同样能够生成统一结构的审核结果，并在前端映射为低、中、高不同风险等级。这说明平台在“真假检测”和“安全审核”两类任务之间已经建立了统一的展示逻辑。

结合当前样例验证情况，平台在明显安全场景和明显风险场景下都能够给出符合任务预期的审核提示。从系统层面看，这一实验结果的意义在于：平台已经具备了将多模态审核接口真正转化为可操作功能的能力，而不是停留在单次接口调用层面。也就是说，本文所实现的不安全内容检测模块不仅能“调通”，还能纳入统一风险展示流程之中。

5.5.3 功能验证结果讨论

从视频与安全审核实验可以看出，当前平台已经完成从技术选型、接口接入到前端展示的关键步骤，下一阶段重点在于扩大样本规模和细化定量指标。先完成多模态链路闭环，再逐步扩展本地模型和系统化评测，是与当前系统完成度相匹配的推进方式。

本阶段视频与安全审核的代表性验证内容如表 5.3 所示。表中没有给出大规模准确率，是因为当前阶段视频与审核样本尚未形成严格标注数据集；本文更关注这些任务是否已经具备稳定输入、结构化返回和统一展示能力。这样的处理能够避免用少量案例得出过度泛化的结论，同时也保留了扩展定量实验的接口基础。

表 5.3: 视频检测与安全审核功能验证内容

验证任务	输入形式	返回字段	验证重点
视频 AI 生成检测	视频 URL 或本地短视频 Base64	真假结论、置信度、模型名称、原因说明	验证视频输入能否通过后端统一转发并映射为虚假检测结果。
图像安全审核	图片 URL 或本地图片 Base64	安全状态、风险标签、处置建议、原因说明	验证多模态审核结果能否映射为低/中/高风险等级。
视频安全审核	视频 URL 或本地短视频 Base64	安全状态、风险标签、处置建议、原因说明	验证视频审核链路能否与图像审核共享展示逻辑。
生成结果回检	平台生成图片或视频	真假检测结果或安全审核结果	验证“生成—检测—展示”闭环是否可运行。

5.6　系统性能与可用性分析

5.6.1　响应特征分析

平台中不同任务的响应模式存在明显差异。图像检测和图像审核任务通常属于相对轻量的同步任务，其结果可以在较短时间内返回，因此更适合直接以同步交互方式呈现。视频生成、图生视频以及部分视频相关理解任务则属于典型的异步长链路任务，需要后端执行轮询和状态封装，再由前端通过加载状态和提示信息等待结果返回。系统当前采用这种“轻任务同步、重任务异步封装”的处理方式，与平台的实际任务特性是匹配的。

从可用性角度看，这种响应组织方式的优势在于，它避免了将复杂的任务状态管理全部压到前端页面中。用户在页面侧只需要感知到“任务正在执行”和“任务已返回结果”这两个主要阶段，而中间的轮询和状态转换由后端统一管理，从而保持了前端交互逻辑的简洁性。

不同任务的响应组织方式如表 5.4 所示。可以看出，平台并没有强行使用一种交互模式处理所有任务，而是根据任务耗时和接口形态区分同步返回与异步轮询，这也是后端代理层存在的直接原因之一。

表 5.4: 不同任务的响应组织方式

任务类型	响应模式	后端处理重点	前端展示重点
图像虚假检测	同步返回	Base64 或 URL 转发、分数与字段归一化	显示真假标签、置信度和模型说明。
图像安全审核	同步返回	审核 JSON 提取、标签与建议映射	显示风险等级、风险标签和处理建议。
视频检测与审核	同步或较长请求	视频 URL/Base64 封装、结构化结果解析	显示视频预览、置信度和说明文本。
文生视频/图生视频	异步轮询	任务提交、状态查询、超时控制和结果 URL 提取	显示加载状态、生成结果和失败提示。

5.6.2　平台可用性分析

平台可用性不仅取决于模型是否能返回结果，还取决于整个交互链路是否清晰。从当前实现来看，平台已经形成了从内容输入、任务选择、结果展示到样本回流的基本闭环，能够覆盖首页导航、内容生成、真假检测、安全审核和结果查看等主要流程。尤其是在前后端职责分离后，不同业务能力虽然来源不同，但在页面层面的交互方式相对统一，这提高了平台整体的一致性。

此外，后端代理层在可用性提升方面发挥了重要作用。它不仅屏蔽了多源接口差异，也通过错误提示和结构化返回降低了用户面对底层异常时的理解成本。可以说，

本文平台的可用性并不是单个模型能力直接决定的，而是由“前端交互 + 后端封装 + 模型服务”共同塑造的。

平台的数据输出与结果管理页面如图 5.2 所示。该页面用于集中展示生成结果和检测记录，是实验回看与样本管理的入口。虽然当前数据管理模块尚未达到生产级资产管理系统的复杂度，但已经为实验记录沉淀和批量统计预留了界面基础。

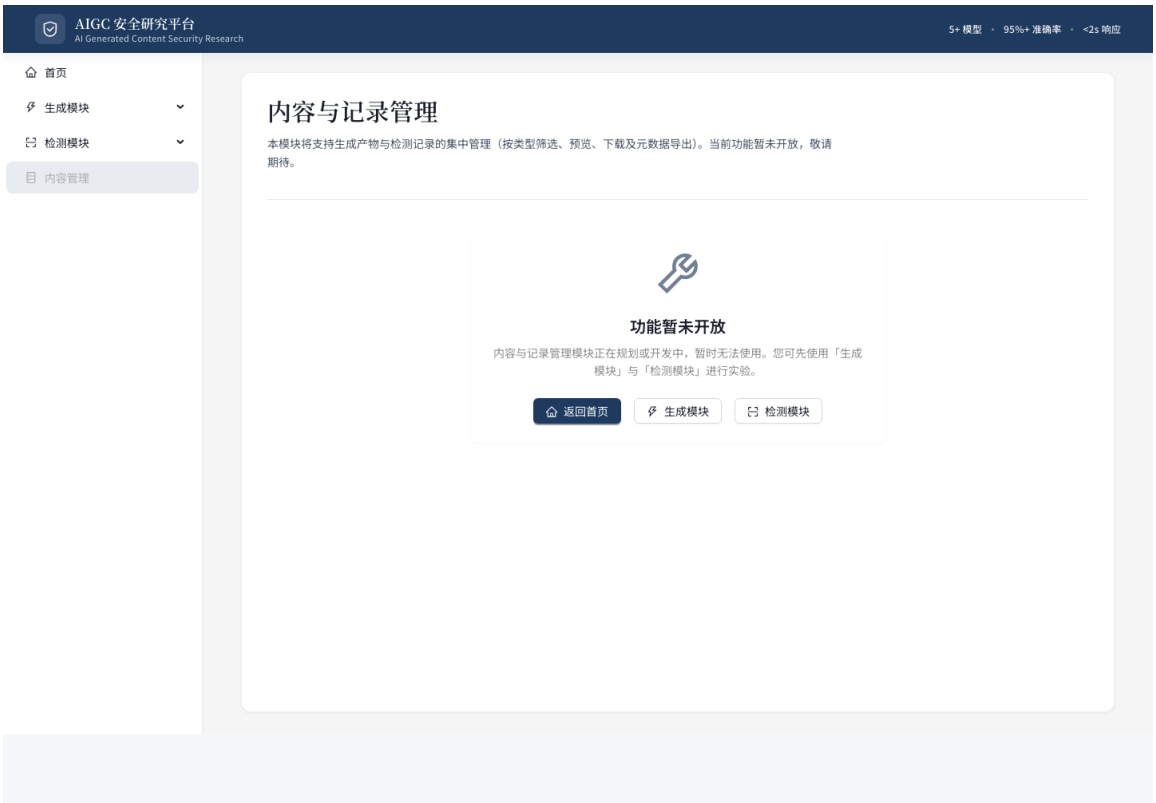

图 5.2: 平台数据输出与结果管理页面

5.7　实验结果综合分析

综合本章实验可以得出以下几点认识。第一，当前平台已经在图像检测、视频检测和不安全内容审核三个方向上形成了完整业务链路，说明总体架构和模块实现具备可行性。第二，图像任务仍然是当前实验最成熟的部分，本地模型与外部接口的双后端方案为更严格的量化对比奠定了基础。第三，视频与安全审核任务虽然当前更偏功能验证和案例分析，但其在平台中的接入方式已经稳定，为扩展本地视频检测模型和更大规模审核实验提供了入口。

从研究价值看，本文实验并未试图把所有任务一次性做成统一大规模 Benchmark，而是结合当前平台阶段，有针对性地验证最关键的系统能力。其优势在于实验结果更贴近平台实际运行状态，能够直接反映系统链路、模型接入和结果展示的可用性。其不足在于，尚未形成覆盖多种本地视频模型和更大规模风险样本的数据化结论，这也

是后续研究需要进一步补强的方向。

5.8　本章小结

本章围绕实验设计、阶段性验证结果和系统分析三个层面，对本文平台进行了综合评估。首先，根据当前项目进展，明确了实验取舍原则，将图像虚假检测作为重点定量验证方向，将视频检测与不安全内容审核作为功能验证和案例分析方向。其次，从实验环境、评价指标、数据集与样本构成等方面搭建了统一实验框架，并基于当前平台样本和测试链路完成了图像、视频与安全审核任务的阶段性分析。最后，从响应特征、交互流程和系统组织方式等角度，对平台的可用性进行了总结。

总体而言，实验结果表明本文平台已经完成了从内容生成、内容检测到结果展示的基本闭环，并在多源能力统一组织方面体现出较好的工程可行性。与此同时，实验也揭示了当前系统在视频本地检测、样本规模和大规模定量评估方面仍有提升空间。

第六章　总结与展望

6.1　全文工作总结

围绕 AIGC 图像与视频内容的真实性风险与安全风险，本文以“方法整合与平台化落地”为主线，完成了面向 AIGC 安全的多模态内容检测与分析平台的设计与实现，并结合实际系统构建过程对关键技术、实现路径和验证方式进行了系统梳理。与单一算法复现类工作不同，本文更强调将图像生成、视频生成、虚假内容检测、不安全内容审核、结果展示与样本管理组织为一个可运行、可扩展、可验证的整体系统，从而使研究工作既具备工程实现基础，也具备后续实验扩展空间。

在理论与方法层面，本文首先梳理了 AIGC 图像与视频生成技术的发展脉络，分析了扩散模型、Deepfake 与多模态生成技术在内容生产中的典型应用形式，并进一步总结了虚假内容检测方法和不安全内容审核方法的主要技术路线。在此基础上，本文结合当前 AIGC 安全治理需求，明确了平台应同时覆盖“真实性判别”和“安全性审核”两类核心任务，为后续系统设计奠定了方法基础。

在系统设计层面，本文从实际应用需求出发，对平台的功能需求、非功能需求和核心业务流程进行了分析，设计了由前端表示层、后端代理层和模型推理层组成的三层架构。该架构一方面能够支持多种本地模型与外部 API 的统一接入，另一方面也有利于将上传、推理、结果解析、风险分级和可视化展示等步骤解耦，从而提升系统的可维护性与扩展性。围绕这一总体架构，本文进一步完成了生成模块、虚假检测模块、不安全检测模块、可视化模块和数据管理模块的职责划分与接口设计。

在工程实现层面，本文以前端 React + TypeScript、后端 Node.js + Express、本地模型服务 Python + FastAPI 的技术组合为基础，实现了平台的关键业务链路。具体而言，平台接入了 UniversalFakeDetect 图像虚假检测模型、本地 Stable Diffusion 文生图模型、本地 ModelScope 文生视频模型，并通过统一代理层封装了图像 AI 鉴别、视频 AI 鉴别、图像安全审核、视频安全审核以及多类内容生成接口。围绕检测结果的展示需求，系统实现了真假判定、置信度、风险标签和结果说明等可视化输出，使平台具备较为完整的交互闭环。

在实验验证层面，本文结合当前项目阶段，对实验设计做了与系统成熟度相匹配的取舍：将图像真假检测作为主要量化验证方向，将视频真假识别和不安全内容审核作为功能链路验证方向，并从可用性角度对平台的响应特征和交互流程进行了分析。实验结果表明，本文所实现的平台已能够完成从内容生成到内容检测、再到结果展示

与分析的基本闭环。其中，UniversalFakeDetect 在 ProGAN mini 子集上完成了本地基线验证，说明当前权重加载、图像预处理、阈值判定和接口封装流程能够正常运行；外部多模态能力则在视频理解和开放场景安全审核方面体现出较高的工程接入效率和覆盖能力。

综合来看，本文完成的主要工作可概括为以下三点：第一，构建了一个面向 AIGC 安全问题的多模态检测与分析平台，将图像、视频、生成和审核等多类能力统一于同一系统之中；第二，提出并实现了本地模型与外部 API 结合的混合检测思路，在研究可控性与工程可用性之间取得了较好的平衡；第三，围绕当前项目阶段完成了系统验证与阶段性分析，为后续扩展更多本地模型、构建更大规模数据集和开展更系统的对比实验提供了基础。

6.2　存在的不足

尽管本文完成了平台主体功能的设计与实现，并形成了较为完整的系统闭环，但从研究深度和系统成熟度角度看，当前工作仍存在若干不足。

第一，本地检测能力仍然偏向图像场景，视频真实性检测与不安全内容审核更多依赖外部多模态接口完成。虽然这一方案能够较快验证完整业务链路，但在自主可控性、可解释性和成本稳定性方面仍存在局限。特别是在视频场景下，当前系统尚未形成与本地图像检测模块同等成熟度的本地判别能力。

第二，实验样本规模和实验组织方式仍有进一步完善空间。现阶段系统已具备公开数据样本、平台生成样本和开放场景样本的混合验证能力，ProGAN mini 子集也验证了本地图像检测链路的可用性，但从毕业论文的严谨性要求出发，仍需在样本规模、类别均衡、生成源多样性、压缩扰动和任务标注规范等方面持续补强。当前实验更适合作为阶段性验证，而不是终局性的全面评测。

第三，多源检测结果的融合策略还较为基础。当前平台已经实现了不同检测能力的统一接入与结果展示，但对于多模型之间的冲突判定、置信度校准、风险评分融合以及解释信息整合，尚未形成系统化的方法设计。平台目前更偏向“多能力汇聚”，距离更高层次的“多模型协同决策”仍有提升空间。

第四，数据管理与结果沉淀能力仍处于逐步完善阶段。当前系统已具备结果展示、样本浏览和基础管理页面，但在历史记录持久化、批量检索、结果导出、统计分析和实验记录复用等方面，仍有继续增强的空间。这也意味着平台当前更适合作为研究型原型系统，而非面向长期业务运行的完整生产系统。

第五，论文当前的实验分析仍以系统验证和工程落地为主要目标，对底层算法机制、跨模型泛化边界和对抗规避能力的深入讨论相对有限。若后续希望将研究进一步推进到更强的方法创新层面，还需要围绕检测器鲁棒性、可解释性和通用性展开更细致的实验与分析。

6.3　后续研究展望

针对上述不足，本文认为后续工作可从以下几个方向继续推进。

首先，可以进一步扩展本地检测模型体系，增强平台的自主检测能力。除了继续优化 UniversalFakeDetect 的应用方式外，还可以引入 CNNDetection、DRCT 等代表性图像检测方法，并探索训练自由或轻量级的视频检测方法在本地部署中的可行性。通过构建覆盖图像与视频的本地模型集合，平台能够在减少外部依赖的同时，为毕业设计后续阶段提供更充分的实验对比基础。

其次，可以围绕数据集构建与实验体系设计开展更系统的工作。后续可将平台生成模块、本地生成模型与公开数据集结合起来，形成更大规模、更具多样性的结构化实验集，并从生成来源、内容场景、后处理方式和风险类别等维度进行分层组织。在此基础上，可进一步补充准确率、召回率、F1 值之外的泛化测试、鲁棒性测试和跨来源测试，从而增强实验结论的说服力。

再次，可以将现有平台从“统一接入框架”进一步推进为“多模型融合框架”。具体而言，可围绕多源输出构建统一风险评分机制，研究不同检测器之间的置信度校准方法、冲突结果仲裁机制以及人机协同审核策略，使系统从单纯展示多个检测结果，发展为能够给出更稳定、更具解释性的综合分析结论。

此外，平台还可以进一步加强结果管理和可解释性分析能力。例如，针对图像场景可补充区域热力图、可疑痕迹说明和模型判定依据摘要；针对视频场景可补充分片段分析、关键帧展示与时间轴风险定位；针对审核场景可进一步形成自动化实验报告或结构化分析报告。此类能力不仅有助于论文展示，也有助于平台在真实审查场景中的实用化。

最后，从更长远的研究视角看，AIGC 安全问题本身仍在快速演化。随着更强的图像、视频和多模态生成模型不断出现，检测方法与治理策略也需要持续更新。未来工作不仅可以关注生成后检测，还可以进一步考虑生成前约束、提示词风险控制、模型安全评测与治理基准构建等更广义的内容安全问题。围绕这些方向持续推进，有望使本课题从当前的系统实现型工作，逐步发展为兼具系统平台价值与方法研究深度的综合性研究。

参考文献

[1] GOODFELLOW I, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets[C]//Advances in Neural Information Processing Systems 27. Red Hook, NY: Curran Associates, 2014: 2672-2680.

[2] KARRAS T, AILA T, LAINE S, et al. Progressive growing of GANs for improved quality, stability, and variation[EB/OL]. (2017-10-26)[2026-04-24]. https://arxiv.org/abs/1710.10196.

[3] KARRAS T, LAINE S, AILA T. A style-based generator architecture for generative adversarial networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Long Beach: IEEE, 2019: 4401-4410.

[4] HO J, JAIN A, ABOADI P. Denoising diffusion probabilistic models[C]//Advances in Neural Information Processing Systems 33. Red Hook, NY: Curran Associates, 2020: 6840-6851.

[5] SONG Y, Sohl-DICKSTEIN J, KINGMA D P, et al. Score-based generative modeling through stochastic differential equations[EB/OL]. (2020-11-26)[2026-04-24]. https://arxiv.org/abs/2011.13456.

[6] ROMBACH R, BLATTMANN A, LORENZ D, et al. High-resolution image synthesis with latent diffusion models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. New Orleans: IEEE, 2022: 10684-10695.

[7] SAHARIA C, CHAN W, CHANG H, et al. Photorealistic text-to-image diffusion models with deep language understanding[C]//Advances in Neural Information Processing Systems 35. Red Hook, NY: Curran Associates, 2022: 36479-36494.

[8] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C]//Proceedings of the 38th International Conference on Machine Learning. New York: PMLR, 2021: 8748-8763.

[9] WANG S Y, WANG O, ZHANG R, et al. CNN-generated images are surprisingly easy to spot... for now[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle: IEEE, 2020: 8692-8701.

[10] OJHA U, LI Y, LEE Y J. Towards universal fake image detectors that generalize across generative models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Vancouver: IEEE, 2023: 24480-24489.

[11] TAN C, ZHAO Y, WEI S, et al. Learning on gradients: generalized artifacts representation for GAN-generated images detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Vancouver: IEEE, 2023: 12105-12114.

[12] CHEN B, ZENG J, YANG J, et al. DRCT: Diffusion reconstruction contrastive training towards universal detection of diffusion generated images[C]//Proceedings of the 41st International Conference on Machine Learning. New York: PMLR, 2024: 7621-7639.

[13] ROSSLER A, COZZOLINO D, VERDOLIVA L, et al. FaceForensics++: Learning to detect manipulated facial images[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. Seoul: IEEE, 2019: 1-11.

[14] LI Y, CHANG M C, LU S, et al. Exposing deepfake videos by detecting face warping artifacts[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. Long Beach: IEEE, 2019: 46-52.

[15] CORVI R, COZZOLINO D, ZINGARINI G, et al. On the detection of synthetic images generated by diffusion models[C]//ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing. Rhodes Island: IEEE, 2023: 1-5.

[16] ZHENG C, SUO R, LIN C, et al. D3: Training-free AI-generated video detection using second-order features[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. Honolulu: IEEE, 2025: 12852-12862.

[17] MIAO Y, ZHU Y, YU L, et al. T2VSafetyBench: Evaluating the safety of text-to-video generative models[C]//Advances in Neural Information Processing Systems 37: Datasets and Benchmarks Track. Red Hook, NY: Curran Associates, 2024.

[18] YEH C, CHANG Y M, CHIU W C, et al. T2Vs meet VLMs: A scalable multimodal dataset for visual harmfulness recognition[C]//Advances in Neural Information Processing Systems 37: Datasets and Benchmarks Track. Red Hook, NY: Curran Associates, 2024.

[19] RUNWAY. Stable Diffusion v1-5 model card[EB/OL]. [2026-04-24]. https://huggingface.co/runwayml/stable-diffusion-v1-5.

[20] ALI-VILAB. Text-to-video-ms-1.7b model card[EB/OL]. [2026-04-24]. https://huggingface.co/ali-vilab/text-to-video-ms-1.7b.

[21] KHAN A A, LAGHARI A A, INAM S A, et al. A survey on multimedia-enabled deepfake detection: state-of-the-art tools and techniques, emerging trends, current challenges & limitations, and future directions[J]. Discover Computing, 2025, 28: 48.

[22] VERDOLIVA L. Media forensics and deepfakes: an overview[J]. IEEE Journal of Selected Topics in Signal Processing, 2020, 14(5): 910-932.

致谢

本论文从选题、系统开发到论文撰写能够顺利推进，离不开许多老师、同学和家人的帮助与支持。在此谨向所有关心和帮助过我的人表示诚挚的感谢。

首先，衷心感谢指导教师在毕业设计全过程中给予的悉心指导。无论是在课题方向的确定、系统方案的设计、研究内容的取舍，还是在论文结构与表达方式的修改上，老师都给予了耐心细致的建议，使我能够逐步从最初的想法整理出较为清晰的研究主线，并在实践过程中不断修正和完善自己的工作。

其次，感谢学院提供的学习环境与实验条件，使本课题能够围绕 AIGC 安全这一具有现实意义的方向持续展开。感谢在项目开发与实验过程中给予帮助的同学和朋友，和大家的交流讨论帮助我在系统实现、模型部署、问题排查和论文写作方面获得了很多启发。

同时，也感谢家人在整个毕业设计期间给予我的理解、支持与鼓励。在课题推进和论文写作压力较大的阶段，家人的陪伴与支持始终是我坚持完成本课题的重要动力。

最后，感谢所有为 AIGC 安全研究、内容治理与相关开源工作做出贡献的研究者和开发者。正是因为这些前人的研究积累与开源成果，本文的系统实现和论文撰写才有了坚实的基础。

谨以此文，向所有帮助、支持和鼓励过我的人致以诚挚谢意。

附录

附录 A 补充代码与接口说明

为便于说明本文系统实现与实验组织的对应关系，现对主要代码模块、功能页面、后端接口及运行端口作补充说明。

1. 前端路由与页面职责。系统前端共包含 6 个核心页面：首页负责平台总览与导航；Deepfake 生成页负责换脸、人脸动画和属性编辑等能力调用；通用生成页负责文生图、文生视频与图生视频任务；虚假内容检测页负责图像与视频真实性检测；不安全内容检测页负责图像与视频审核；数据管理页负责结果浏览与后续扩展的数据管理功能。相关路由集中定义于 `src/routes/index.tsx`。

2. 后端接口组织。后端代理服务集中实现于 `server/index.cjs`，当前已封装的主要接口如表 6.1 所示。

这一组织方式使前端能够通过统一入口调用不同来源的能力，并由后端负责密钥隔离、参数封装和结果归一化。

3. 本地服务运行端口。依据当前系统部署方案，后端代理服务运行在 3001 端口，UniversalFakeDetect 服务运行在 8008 端口，Stable Diffusion 文生图服务运行在 8009 端口，ModelScope 文生视频服务运行在 8011 端口。前端生产环境页面通过静态资源方式部署，实验阶段访问地址可根据服务器配置进行调整。

4. 样本与资源目录。平台实验过程中使用的样本主要来源于三部分：公开数据样本目录 `datasets/`，平台生成和功能验证所需资源目录 `public/mock/`，以及系统实现文档所在的 `docs/` 目录。通过将公开数据样本、平台生成样本和开放场景样本进行组合，本文能够在当前阶段完成针对图像真假检测、视频链路验证和内容安全审核的实验组织。

附录 B 运行与复现实验说明

为保证本课题具备较好的可复现性，本文在系统运行与实验组织方面采用如下约定。

1. 环境配置。前端采用 React、TypeScript 与 Vite 进行构建，后端采用 Node.js 与 Express 实现代理层，本地模型服务采用 Python、FastAPI 与 PyTorch 进行封装。各模

表 6.1: 后端代理服务主要接口

接口类型	接口路径	主要功能
检测类	/api/detect/universal-fake-detect	调用 UniversalFakeDetect 本地模型，对单张图像进行真实/伪造判别。
检测类	/api/detect/volc-image-aigc	调用火山方舟视觉理解能力，对图像是否为 AI 生成内容进行判断。
检测类	/api/detect/volc-video-aigc	调用火山方舟视频理解能力，对视频是否存在 AI 生成或深度伪造风险进行判断。
检测类	/api/detect/volc-ims	调用图像内容安全审核能力，识别暴力、色情、敏感等不安全内容。
检测类	/api/detect/volc-video-ims	调用视频内容安全审核能力，对视频片段进行不安全内容识别。
生成类	/api/generate/faceswap	调用火山视觉智能人像融合接口，实现人脸替换生成。
生成类	/api/generate/seededit	调用 SeedEdit 图像编辑能力，根据文本指令修改输入图像。
生成类	/api/generate/fomm	调用图生视频能力，根据单张人脸图像和动作描述生成人脸动画。
生成类	/api/generate/image	调用火山方舟文生图能力，根据提示词生成图像。
生成类	/api/generate/image-stable-diffusion	转发至自托管 Stable Diffusion 服务，完成本地文生图生成。
生成类	/api/generate/model-scope	转发至自托管 ModelScope 服务，完成本地文生视频生成。
生成类	/api/generate/t2v	调用火山方舟文生视频能力，根据文本描述生成视频。
生成类	/api/generate/i2v	调用火山方舟图生视频能力，根据参考图像和文本描述生成视频。

块通过 HTTP 接口通信，便于本地开发与远程部署切换。

2. 部署方式。项目根目录保留的主要部署脚本和运行方式包括：

- 快速部署.sh：用于前端静态资源构建、上传与快速部署；
- deploy-backend.sh：用于后端代理服务部署、依赖安装与进程启动；
- tmux 会话：用于在实验阶段保持后端代理服务和本地模型服务持续运行；
- 本地开发模式：可通过 npm run dev 同时启动前端页面与本地后端代理，便于接口联调和页面验证。

上述方式分别面向前端页面部署、后端服务部署、长期运行维护和本地联调场景。实验阶段，本地模型服务和后端服务可通过 tmux 会话保持运行，以支持持续调试和结果复核。

3. 实验复现思路。若需复现本文实验，可优先完成后端与本地模型服务的启动，随后从前端页面依次验证图像真假检测、视频真假检测、图像安全审核、视频安全审核以及生成模块。对于图像真实性实验，可直接使用 datasets/test/progan/ 下的样本；对于链路验证任务，可结合 public/mock/ 下的测试媒体进行页面级验证。

4. 说明。由于本文对应系统仍处于毕业设计持续完善阶段，部分模块在后续版本中可能继续调整交互形式、结果展示样式与数据管理能力，但总体架构、接口划分和核心功能链路保持不变。